

Companheiro de sala de aula: negócios

· G. Tomas M. Hult · Christian M. Ringle ·
Marko Sarstedt · Nicholas P. Danks ·
Soumya Ray

Parcialmente menos Quadrados Estruturais Modelagem de equações (PLS-SEM) Usando R

Um livro de exercícios

OPEN ACCESS



Springer

Companheiro de sala de aula: negócios

A série Classroom Companion em Negócios apresenta livros básicos e introdutórios voltados para que os alunos aprendam os conceitos principais, métodos fundamentais, teorias e ferramentas do assunto. Os livros oferecem uma base firme para os alunos se preparando para avançar em direção ao aprendizado avançado. Cada livro segue uma estrutura didática clara e apresenta oportunidades fáceis de adoção para os palestrantes.

Mais informações sobre esta série em <http://www.springer.com/series/16374>

Joseph F. Hair Jr. • G. Tomas M. Hult

Christian M. Ringle • Marko Sarstedt

Nicholas P. Danks • Soumya Ray

Parcialmente menos


Quadrados Estruturais


Modelagem de equações


(PLS-SEM) Usando R

Um livro de exercícios

Joseph F. Hair Jr.
Faculdade de Administração Mitchell
Universidade do Sul do Alabama
Móvel, AL
EUA

Christian M. Ringle 
Departamento de Ciência e
Tecnologia de Gestão
Universidade de Tecnologia de Hamburgo
Hamburgo, Alemanha

Escola de Negócios 
Trinity Nicholas P. Danks
Faculdade Trinity
Dublin, Irlanda

Faculdade de 
Administração G. Tomas M. Hult Broad
Universidade Estadual de Michigan
East Lansing, Michigan
EUA

Marco Sarstedt 
Universidade Otto-von-Guericke de Magdeburgo
Magdeburg, Alemanha

Universidade Babeş-Bolyai
Faculdade de Economia e Negócios
Administração

Cluj, Romênia

Soumya Ray 
Universidade Nacional Tsing Hua
Hsinchu, Taiwan



Este livro é uma publicação de acesso aberto.

ISSN 2662-2866 ISSN 2662-2874 (eletrônico)
Companheiro de sala de aula: negócios
ISBN 978-3-030-80518-0 ISBN 978-3-030-80519-7 (e-book)
<https://doi.org/10.1007/978-3-030-80519-7>

© O(s) Editor(es) (se aplicável) e O(s) Autor(es) 2021

Acesso aberto Este livro está licenciado sob os termos da Licença Internacional Creative Commons Atribuição 4.0 (<http://creativecommons.org/licenses/by/4.0/>), que permite uso, compartilhamento, adaptação, distribuição e reprodução em qualquer meio ou formato, desde que você dê os devidos créditos ao(s) autor(es) original(ais) e à fonte, forneça um link para a licença Creative Commons e indique se alterações foram feitas.

As imagens ou outros materiais de terceiros neste livro estão incluídos na licença Creative Commons do livro, a menos que indicado de outra forma em uma linha de crédito para o material. Se o material não estiver incluído na licença Creative Commons do livro e seu uso pretendido não for permitido por regulamentação estatutária ou exceder o uso permitido, você precisará obter permissão diretamente do detentor dos direitos autorais.

O uso de nomes descritivos gerais, nomes registrados, marcas comerciais, marcas de serviço, etc. nesta publicação não implica, mesmo na ausência de uma declaração específica, que tais nomes estejam isentos das leis e regulamentos de proteção relevantes e, portanto, livres para uso geral.

O editor, os autores e os editores estão seguros em assumir que os conselhos e informações neste livro são considerados verdadeiros e precisos na data da publicação. Nem o editor, nem os autores ou os editores dão garantia, expressa ou implícita, com relação ao material aqui contido ou por quaisquer erros ou omissões que possam ter sido feitos. O editor permanece neutro com relação a reivindicações jurisdicionais em mapas publicados e afiliações institucionais.

Este selo Springer é publicado pela empresa registrada Springer Nature Switzerland AG
O endereço da empresa registrada é: Gewerbestrasse 11, 6330 Cham, Suíça

Prefácio

Em 2021, a terceira edição do nosso livro introdutório *A Primer on Partial Least Squares Structural Equation Modeling (PLS-SEM)* foi publicada (Hair, Hult, Ringle e Sarstedt, 2022). O livro abrange os últimos desenvolvimentos no campo, incluindo avanços recentes na avaliação de modelos (por exemplo, testes de inferência na avaliação de validade discriminante, avaliações de poder preditivo usando PLSpredict e comparações de modelos), diretrizes aprimoradas para tamanhos mínimos de amostra e novos métodos e conceitos complementares, como análise de condição necessária e endogeneidade. O livro tem sido altamente bem-sucedido, como evidenciado em sua contagem de citações de mais de 24.000 vezes de acordo com o Google Scholar (em agosto de 2021) e nas traduções para sete outros idiomas, incluindo alemão (Hair et al., 2017), italiano (Hair et al., 2020) e espanhol (Hair et al., 2019). Uma das características do livro que provavelmente contribuiu para sua popularidade é nosso forte foco em elementos pedagógicos, principalmente nossa dependência de um único estudo de caso em execução e do software comercial SmartPLS 3 (Ringle, Wende e Becker, 2015), que se destaca devido ao seu design sem atrito, permitindo que pesquisadores novatos especifiquem e estimem rapidamente modelos de caminho PLS (Memon et al., 2021; Sarstedt e Cheah, 2019).

Embora o SmartPLS constitua o software mais frequentemente usado para conduzir análises PLS-SEM (Ghasemy, Teeroovengadam, Becker e Ringle, 2020; Hair, Hollingsworth, Randolph e Chong, 2017; Usakli e Kucukergin 2018), a pesquisa apresentou vários pacotes para o ambiente R, como csem (Rademaker et al., 2020), SEMinR (Ray et al., 2021) e semPLS (Monecke e Leisch, 2012; Monecke e Leisch, 2013), cujo uso ganhou força recentemente. Entre os pacotes R disponíveis no CRAN, o pacote SEMinR de Ray et al. (2021) traz uma sintaxe particularmente amigável para criar e estimar modelos de equações estruturais usando funções nomeadas apropriadamente para as facetas dos modelos de caminho PLS com os quais os pesquisadores aplicados estão familiarizados: “multi-item” versus “item único”, “construções”, “caminhos” e assim por diante. O pacote também oferece aos usuários funções intuitivas para gerar construções de ordem superior e termos de interação, a flexibilidade para implementar e inserir rapidamente suas próprias extensões, como métodos de imputação de dados ausentes ou visualizações, e gerar relatórios e figuras para resultados de pesquisa. Era lógico, portanto, preparar uma versão do livro que compartilhasse os conceitos metodológicos e também apresentasse o software R como um método para estimar modelos de caminho PLS. Este livro atende a esse objetivo.

Projetamos o texto como uma apostila para leitores que já foram expostos ao PLS-SEM por meio da leitura de livros didáticos (por exemplo, Hair et al., 2022; Henseler, 2021; Ramayah, Cheah, Chuah, Ting e Memon, 2016; Mehmetoglu e Venturini, 2021; Wong, 2019) ou artigos seminais (por exemplo, Chin, 1998; Hair, Ringle e Sarstedt, 2011; Hair, Risher, Ringle e Sarstedt, 2019; Henseler, Ringle e Sinkovics, 2009; Sarstedt, Ringle e Hair, 2022; Tenenhaus, Esposito Vinzi, Chatelin e Lauro, 2005) sobre o método. No entanto, para permitir que leitores com pouca experiência em PLS-SEM compreendam rapidamente os conceitos, cada capítulo oferece uma visão geral concisa de tópicos e métricas relevantes para a execução do PLS-SEM e interpretação dos resultados.

Acompanhado por um rico conjunto de referências para leituras adicionais, regras práticas em

cada capítulo fornece diretrizes sobre as melhores práticas na aplicação do PLS-SEM. O foco, no entanto, está na descrição aprofundada do estudo de caso, que dá aos leitores o “como fazer” de usar o SEMinR para obter soluções e relatar seus resultados. Correspondentemente, a apostila coloca menos ênfase em aspectos relacionados ao design do modelo e à especificação do modelo de medição, mas, em vez disso, introduz o ambiente R e, particularmente, o pacote SEMinR em detalhes.

No entanto, a pasta de trabalho incorpora muitos dos novos recursos que foram introduzidos na terceira edição do *Primer on Partial Least Squares Structural Equation Modeling (PLS-SEM)* (Hair et al., 2022) e oferece conteúdo exclusivo adaptado ao pacote SEMinR. Isso inclui o seguinte:

- 5 Uma visão geral das pesquisas mais recentes sobre a natureza da modelagem baseada em compósitos, que é a base conceitual do PLS-SEM
- 5 Detalhes sobre a distinção entre PLS-SEM e CB-SEM, bem como os objetivos da pesquisa e as constelações de modelos, que são favoráveis ao uso de PLS-SEM
- 5 Aplicação de PLS-SEM com dados secundários (de arquivo)
- 5 Diretrizes para determinar tamanhos mínimos de amostra usando a raiz quadrada inversa método
- 5 Cobertura detalhada da confiabilidade da consistência interna usando ρ_A e inferência teste na avaliação da validade discriminante
- 5 Últimas pesquisas sobre configurações e avaliação de bootstrapping
- 5 Analisando o poder preditivo fora da amostra de um modelo usando o PLSpredict procedimento
- 5 Métricas para comparações de modelos (por exemplo, o critério de informação bayesiano)
- 5 Cobertura da literatura mais recente sobre PLS-SEM

Todos os exemplos na edição se aplicam à versão mais recente do pacote SEMinR, que está disponível gratuitamente no CRAN (7 <https://CRAN.R-project.org/pacote=seminr>; veja também 7 Cap. 3). Os capítulos do livro e os suplementos de suporte de aprendizagem são organizados em torno dos resultados de aprendizagem mostrados no início de cada capítulo. Além disso, cada capítulo inclui um único resumo conciso para os resultados de aprendizagem. O site 7 <https://www.pls-sem.com> inclui uma série de materiais de apoio para facilitar o aprendizado e a aplicação do método PLS-SEM e o uso do pacote SEMinR.

Visite 7 <https://www.pls-sem.com> para acesso aos documentos de marcação R, que reúnem descrições e códigos que podem ser facilmente copiados para o console R.

Além disso, a PLS-SEM Academy (7 <https://www.pls-sem-academy.com>) oferece cursos on-line baseados em vídeo baseados neste livro. Os cursos incluem conteúdos básicos como especificação e avaliação de modelos, bem como tópicos avançados, incluindo mediação, construções de ordem superior, moderação, invariância de medição, análise multigrupo e efeitos não lineares.

Além de várias horas de material de vídeo online apresentado por instrutores de renome mundial, a PLS-SEM Academy oferece slides de palestras abrangentes que

ilustrar todas as análises passo a passo. Enquanto as descrições do estudo de caso se baseiam no software SmartPLS, os conceitos são totalmente aplicáveis às análises baseadas no software R usando o pacote SEMinR. Usuários registrados podem reivindicar certificados de curso após a conclusão bem-sucedida de cada exame de fim de seção.

Acesso com desconto à PLS-SEM Academy

A PLS-SEM Academy oferece a todos os proprietários deste livro um desconto de 15% na compra de acesso às suas ofertas de cursos. Tudo o que você precisa fazer é enviar uma foto sua com o livro em mãos, seu nome e endereço para o endereço de e-mail support@pls-sem-academy.com. Pouco tempo depois, você receberá um código de desconto de 15% que poderá usar no site [7 https://www.pls-sem-academy.com](https://www.pls-sem-academy.com). Esperamos que você goste de aperfeiçoar suas habilidades em PLS-SEM com a ajuda desses cursos e desejamos muito sucesso na obtenção dos certificados.

Gostaríamos de reconhecer os muitos insights e sugestões fornecidos pelos colegas, alunos e usuários do PLS-SEM em todo o mundo. Mais notavelmente, agradecemos a Nicole Beachum (Universidade do Alabama, Birmingham), Jan-Michael Becker (BI Norwegian Business School), Zakariya Belkhamza (Ahmed Bin Mohammed Military College), Charla Brown (Troy University), Roger Calantone (Michigan State University), Fabio Cassia (Universidade de Verona), Gabriel Cepeda Carrión (Universidade de Sevilha), Jacky Jun Hwa Cheah (Universiti Putra Malaysia), Adamantios Diamantopoulos (Universidade de Viena), Markus Eberl (Kantar), George Franke (Universidade do Alabama), Anne Gottfried (Universidade do Texas, Arlington), Siegfried P. Gudergan (Universidade de Waikato), Saurabh Gupta (Kennesaw State University), Karl-Werner Hansmann (Universidade de Hamburgo), Dana Harrison (East Tennessee State University), Sven Hauff (Helmut Schmidt University), Mike Hollingsworth (Universidade Old Dominion), Philip Holmes (Pensacola Christian College), Chris Hopkins (Universidade Auburn), Lucas Hopkins (Universidade Estadual da Flórida), Maxwell K. Hsu (Universidade de Wisconsin), Heungsun Hwang (Universidade McGill), Ida Rosnita Ismail (Universidade Kebangsaan Malaysia), April Kemp (Universidade do Sudeste da Louisiana), David Ketchen (Universidade Auburn), Ned Kock (Universidade Texas A&M), Marcel Lichters (TU Chemnitz), Benjamin Liengaard (Universidade Aarhus), Chein-Hsin Lin (Universidade Da-Yeh), Yide Liu (Universidade de Ciência e Tecnologia de Macau), Francesca Magno (Universidade de Bergamo), Lucy Matthews (Universidade Estadual do Tennessee Médio), Jay Memmott (Universidade de Dakota do Sul), Mumtaz Ali Memon (Escola de Negócios NUST), Adam Merkle (Universidade do Sul do Alabama), Ovidiu I. Moiescu (Universidade Babeş-Bolyai), Zach Moore (Universidade de Louisiana em Monroe), Arthur Money (Henley Business School), Christian Nitzl (Universität der Bundeswehr München), Torsten Pieper (Universidade da Carolina do Norte), Dorian Proksch (Universidade de Twente), Lacramioara Radomir (Universidade Babeş-Bolyai), Arun Rai (Universidade Estadual da Geórgia), Sascha Raithel (Freie Universität Berlin), S. Mostafa Rasooli-manesh (Taylors University), Lauren Rich (University of West Florida), Nicole

Richter (Universidade do Sul da Dinamarca), Edward E. Rigdon (Universidade Estadual da Geórgia), Jeff Risher (Universidade do Sudeste de Oklahoma), José Luis Roldán (Universidade de Sevilha), Amit Saini (Universidade de Nebraska-Lincoln), Phillip Samouel (Universidade de Kingston), Francesco Scafarto (Universidade de Roma “Tor Vergata”), Bruno Schivinski (Universidade de Londres), Rainer Schlittgen (Universidade de Hamburgo), Manfred Schwaiger (Universidade Ludwig-Maximilians), Pratyush N. Sharma (Universidade do Alabama), Wen-Lung Shiau (Universidade de Tecnologia de Zhejiang), Galit Shmueli (Universidade Nacional Tsing Hua), Donna Smith (Universidade Ryerson), Toni M. Somers (Universidade Estadual Wayne), Detmar W. Straub (Universidade Estadual da Geórgia), Ramayah Thurasamy (Universidade Sains Malaysia), Hiram Ting (Universidade UCSI), Ron Tsang (Agnes Scott College), Huiwen Wang (Universidade Beihang), Sven Wende (SmartPLS GmbH), Anita Whiting (Universidade Estadual Clayton), David Williams (Universidade Estadual Dalton) e Lea Witta (Universidade da Flórida Central) por seus comentários úteis.

Agradecemos também à equipe de doutorandos e pesquisadores da Universidade de Tecnologia de Hamburgo e da Universidade Otto-von-Guericke de Magdeburg. nomeadamente, Michael Canty, Svenja Damberg, Lena Frömbing, Frauke Kühn, Benjamin Maas, Mandy Pick e Martina Schöninger—pelo seu gentil apoio. Em particular, gostaríamos de agradecer a Susanne Adler que traduziu o conteúdo do livro para documentos R markdown, disponíveis em **7** <https://www.pls-sem.net>. Além disso, na Springer agradecemos a Ruth Milewski e Prashanth Mahagaonkar por seu suporte e ótimo trabalho. Esperamos que a versão do software R do nosso livro expanda o conhecimento das capacidades e benefícios do PLS-SEM para um grupo muito mais amplo de pesquisadores e profissionais. Por fim, se você tiver quaisquer comentários, sugestões ou ideias para melhorar este livro, entre em contato conosco. Agradecemos qualquer feedback sobre o conceito e o conteúdo do livro!

Visite o site complementar deste livro em **7** <https://www.pls-sem.com>.

Joseph F. Hair Jr.

Mobile, AL, EUA

G. Tomás M. Hult

East Lansing, MI, EUA

Christian M. Ringle

Hamburgo, Alemanha

Marco Sarstedt

Magdeburg, Alemanha

Nicholas P. Danks

Dublin, Irlanda

Soumya Ray

Hsinchu, Taiwan

Referências

- Chin, W. W. (1998). A abordagem dos mínimos quadrados parciais para modelagem de equações estruturais. Em G. A. Marcoulides (Ed.), *Métodos modernos para pesquisa empresarial* (pp. 295–358). Mahwah, NJ: Erlbaum.
- Ghasemy, M., Teeroovengadam, V., Becker, J.-M., & Ringle, C. M. (2020). Este carro rápido pode se mover mais rápido: Uma revisão da aplicação PLS-SEM na pesquisa do ensino superior. *Ensino Superior*, 80, 1121–1152.
- Hair, J. F., Hollingsworth, C. L., Randolph, A. B., & Chong, A. YL (2017a). Uma avaliação atualizada e expandida do PLS-SEM na pesquisa de sistemas de informação. *Industrial Management & Data Systems*, 117(3), 442–458.
- Hair, J. F., Hult, G. TM, Ringle, C. M., & Sarstedt, M. (2022). *Uma cartilha sobre modelagem de equações estruturais de mínimos quadrados parciais (PLS-SEM)* (3ª ed.). Thousand Oaks, CA: Sage.
- Hair, J. F., Hult, G. TM, Ringle, C. M., Sarstedt, M., Castillo Apraiz, J., Cepeda-Carrión, G., & Roldán, J. L. (2019a). *Manual de modelagem de equações estruturais de mínimos quadrados parciais (PLS-SEM)*. (Segunda Edição). Barcelona: OmniaScience.
- Hair, JF, Hult, G. TM, Ringle, CM, Sarstedt, M., Magno, F., Cassia, F., & Scafarto, F. (2020). *Le Equazioni Strutturali Partial Least Squares: Introdução ao PLS-SEM*. (Segunda Edição). Milão: Franco Angeli.
- Hair, JF, Hult, G. TM, Ringle, CM, Sarstedt, M., Richter, NF, & Hauff, S. (2017b). *Modelo de estrutura de mínimos quadrados parciais (PLS-SEM): Eine anwendungsorientierte Einführung*. Munique: Vahlen.
- Hair, J. F., Ringle, C. M., & Sarstedt, M. (2011). PLS-SEM: De fato uma bala de prata. *Journal of Marketing Theory and Practice*, 19(2), 139–151.
- Hair, J. F., Risher, J. J., Sarstedt, M., & Ringle, C. M. (2019b). Quando usar e como relatar os resultados do PLS-SEM. *European Business Review*, 31(1), 2–24.
- Henseler, J. (2021). *Modelagem de equações estruturais baseada em compósitos: analisando variáveis latentes e emergentes capazes*. Nova York, NY: Guilford Press.
- Henseler, J., Ringle, C. M., & Sinkovics, R. R. (2009). O uso de modelagem de caminho de mínimos quadrados parciais em marketing internacional. Em R. R. Sinkovics & P. N. Ghauri (Eds.), *Novos desafios para o marketing internacional*. (Advances in International Marketing, 20 (pp. 277–319). Bingley: Emerald.
- Mehmetoglu, M., & Venturini, S. (2021). *Modelagem de equações estruturais com mínimos quadrados parciais usando Stata e R*. Londres: Routledge.
- Memon, M. A., Ramayah, T., Cheah, J.-H., Ting, H., Chuah, F., & Cham, T. H. (2021). Programas estatísticos PLS-SEM: Uma revisão. *Journal of Applied Structural Equation Modeling*, 5(1), i–xiv.
- Monecke, A., & Leisch, F. (2012). semPLS: Modelagem de equações estruturais usando mínimos quadrados parciais. *Revista de Software Estatístico*, 48(3), 1–32.
- Monecke, A., & Leisch, F. (2013). *Pacote R semPLS: Modelagem de equações estruturais usando mínimos quadrados parciais versão 1.0-10 [software de computador]*. Recuperado de 7 <https://cran.r-project.org/web/packages/semPLS/>
- Rademaker, ME, Schuberth, F., Schamberger, T., Kiesel, M., Dijkstra, TK, & Henseler, J. (2020). *Pacote R cSEM: Composite-based structural equation modeling versão 0.3.0 [software de computador]*. Recuperado de: 7 <https://cran.r-project.org/web/packages/cSEM/>
- Ramayah, T., Cheah, J.-H., Chuah, F., Ting, H., & Memon, M. A. (2016). *Modelagem de equações estruturais de mínimos quadrados parciais (PLS-SEM) usando SmartPLS 3.0: Um guia atualizado e prático para análise estatística*. Kuala Lumpur: Pearson Malaysia.
- Ray, S., Danks, N. P., Calero Valdez, A. (2021). *Pacote R semr: Linguagem específica de domínio para construção e estimativa de modelos de equações estruturais versão 2.1.0 [software de computador]*. Recuperado de: 7 <https://cran.r-project.org/web/packages/seminr/>
- Ringle, CM, Wende, S., & Becker, J.-M. (2015). *SmartPLS 3 [software de computador]*. Bonningstedt: SmartPLS. Recuperado de 7 <https://www.smartpls.com>
- Sarstedt, M., & Cheah, J. H. (2019). Modelagem de equações estruturais de mínimos quadrados parciais usando Smart-PLS: Uma revisão de software. *Journal of Marketing Analytics*, 7(3), 196–202.
- Sarstedt, M., Hair, JF, & Ringle, CM (2022). Modelagem de equações estruturais de mínimos quadrados parciais. Em C. Homburg, M. Klarmann, & A. Vomberg (Eds.), *Handbook of Market Research*. Cham: Springer.

Tenenhaus, M., Esposito Vinzi, V., Chatelin, Y.-M., & Lauro, C. (2005). Modelagem de caminho PLS. *Computador Estatísticas e Análise de Dados*, 48(1), 159–205.

Usakli, A., & Kucukergin, K. G. (2018). Usando modelagem de equações estruturais de mínimos quadrados parciais em hospitalidade e turismo: os pesquisadores seguem diretrizes práticas? *International Journal of Con-temporary Hospitality Management*, 30(11), 3462–3512.

Wong, K. K.-K. (2019). *Dominando a modelagem de equações estruturais de mínimos quadrados parciais (PLS-SEM) com SmartPLS em 38 horas*. Bloomington, IN: iUniverse.

Conteúdo


1	Uma introdução à modelagem de equações estruturais	1
2	Visão geral do R e do RStudio	31
3	O pacote SEMinR	49
4	Avaliação de Modelos de Medição Reflexiva	75
5	Avaliação de Modelos de Medição Formativa	91
6	Avaliação do Modelo Estrutural	115
7	Análise de Mediação	139
8	Análise de Moderação	155
	Informações suplementares	
	Apêndice A: O algoritmo PLS-SEM	174
	Apêndice B: Avaliação dos construtos medidos reflexivamente no modelo de reputação corporativa	177
	Glossário	
	Índice	

Sobre os autores



Joseph F. Hair Jr.

é Cleverdon Chair of Business e diretor do doutorado em administração de empresas, Mitchell College of Business, University of South Alabama. Anteriormente, ele ocupou a Copeland Endowed Chair of Entrepreneurship e foi diretor do Entrepreneurship Institute, Ourso College of Business Administration, Louisiana State University. Joe foi reconhecido pela Clarivate Analytics em 2018, 2019 e 2020 por estar no top 1% globalmente de todos os professores de negócios e economia com base em suas citações e realizações acadêmicas, que excedem 251.000 ao longo de sua carreira. O professor Hair é autor de mais de 75 livros, incluindo *Multivariate Data Analysis* (8ª edição, 2019; citado mais de 150.000 vezes), *MKTG* (13ª edição, 2020), *Essentials of Business Research Methods* (2020) e *Essentials of Marketing Research* (4ª edição, 2020). Ele também publicou vários artigos em periódicos acadêmicos e foi reconhecido como o *Educador de Marketing do Ano da Academy of Marketing Science*. Como um palestrante convidado popular, o Professor Hair frequentemente apresenta seminários sobre técnicas de pesquisa, análise de dados multivariados e questões de marketing para organizações na Europa, Austrália, China, Índia e América do Sul. Ele tem um novo livro sobre *Essentials of Marketing Analytics*, 2021 (McGraw-Hill).



G. Tomás M. Hult

é professor e Byington Endowed Chair na Michigan State University (EUA), e ocupa uma cátedra visitante na Leeds University Business School (Reino Unido) e uma cátedra visitante na Uppsala University (Suécia). O professor Hult é membro das Redes de Especialistas do Fórum Econômico Mundial e do Fórum Mundial de Investimentos das Nações Unidas/UNCTAD e também faz parte da Equipe de Especialistas do American Customer Satisfaction Index (ACSI). O professor Hult foi reconhecido em 2016 como o *Academy of Marketing Science/CUTCO-Vector Distinguished Marketing Educator*; é membro eleito da Academy of International Business; e está entre os 10 melhores acadêmicos em marketing pelo prestigiado *World Ranking of Scientists*. Na Universidade Estadual de Michigan, o Professor Hult foi reconhecido com o Prêmio Beal Outstanding Faculty em 2019 (o maior prêmio da MSU "por excelente serviço total à Universidade"), e também foi reconhecido com o Prêmio John Dunning AIB Service por excelente serviço ao AIB.

como o diretor executivo mais antigo na história do AIB (2004–2019) (o prêmio de serviço mais prestigiado concedido pela Academy of International Business). O professor Hult regularmente dá seminários de doutorado

em estatística multivariada, modelagem de equações estruturais e modelagem linear hierárquica em todo o mundo. Ele é cidadão duplo da Suécia e dos Estados Unidos. Mais informações sobre o Professor Hult podem ser encontrado em 7 <http://www.tomashult.com>.



Christian M. Ringle

é professor catedrático de administração na Universidade de Tecnologia de Hamburgo (Alemanha). Sua pesquisa aborda a administração de organizações, administração de recursos humanos e desenvolvimento de métodos para análise de negócios e sua aplicação à pesquisa empresarial. Suas contribuições nesses campos foram publicadas em periódicos como *International Journal of Research in Marketing*, *Information Systems Research*, *Journal of the Academy of Marketing Science*, *MIS Quarterly*, *Organizational Research Methods* e *The International Journal of Human Resource Management*. Desde 2018, ele foi nomeado membro da Lista de Pesquisadores Altamente Citados da Clarivate Analytics. Em 2014, o professor Ringle foi cofundador da SmartPLS (7 [https://www.](https://www.smartpls.com)

[smartpls.com](https://www.smartpls.com)), uma ferramenta de software com uma interface gráfica de usuário para a aplicação do método de modelagem de equações estruturais de mínimos quadrados parciais (PLS-SEM). Além de dar suporte a consultorias e corporações internacionais, ele regularmente ministra seminários de doutorado sobre análise de negócios, métodos de aprendizado de máquina, estatística multivariada, o método PLS-SEM e o uso do SmartPLS em todo o mundo. Mais informações sobre o Professor Christian M. Ringle podem ser encontradas em 7 <https://www.tuhh.de/hrmo/team/prof-dr-cm-ringle.html>.



Marco Sarstedt

é professor catedrático de marketing na Ludwig-Maximilians-University Munich (Alemanha) e professor adjunto na Babeş-Bolyai University, Romênia. Seu principal interesse de pesquisa é o avanço de métodos de pesquisa para melhorar a compreensão do comportamento do consumidor. Sua pesquisa foi publicada na *Nature Human Behavior*, *Journal of Marketing Research*, *Journal of the Academy of Marketing Science*, *Multivariate Behavioral Research*, *Organizational Research Methods*, *MIS Quarterly* e *Psychometrika*, entre outros. Sua pesquisa está entre as mais frequentemente citadas nas ciências sociais.

O professor Sarstedt ganhou vários prêmios de melhor artigo e citação, incluindo cinco *Emerald Citations of Excellence Awards* e dois *AMS William R. Darden Awards*. De acordo com o ranking FAZ de 2020, ele está entre os pesquisadores mais influentes na Alemanha, Áustria e Suíça. O professor Sarstedt foi nomeado membro da Clarivate

Lista de Pesquisadores Altamente Citados da Analytics, que inclui os "pesquisadores científicos mais impactantes do mundo".



Nicholas P. Danks

é professor assistente de análise de negócios no Trinity College, Dublin. Sua pesquisa se concentra em modelagem de equações estruturais, mínimos quadrados parciais, metodologia preditiva e programação. Nicholas é coautor e principal mantenedor do SEMinR, um pacote de código aberto para o R Statistical Environment para estimativa e avaliação de modelos de equações estruturais. Ele recebeu o prêmio William R. Darden Best Marketing Research Paper na conferência da Academy of Marketing Science. Sua pesquisa foi publicada no Human Resource Management Journal, *Journal of Business Research* e *Decision Sciences*.



Soumya Ray

Soumya Ray é professor associado no Institute of Service Science da National Tsing Hua University. Ele é o cocriador do pacote SEMinR para modelagem de equações estruturais para a plataforma R. Seus interesses de pesquisa incluem comportamento do usuário online e métodos aplicados, e seu trabalho foi publicado em *Information Systems Research*, *Journal of Management Information Systems*, *Decision Sciences* e outros. Seus interesses de ensino e desenvolvimento incluem arquitetura de sistemas, segurança da informação e estatística computacional.



Uma introdução à estrutura Equação Modelagem

Conteúdo

- 1.1 O que é modelagem de equações estruturais? – 3**
- 1.2 Princípios de Estrutural Modelagem de equações – 4**
 - 1.2.1 Modelos de Caminho com Latente Variáveis – 4
 - 1.2.2 Testando relacionamentos teóricos – 7
 - 1.2.3 Teoria da Medição – 7
 - 1.2.4 Teoria Estrutural – 8
- 1.3 PLS-SEM e CB-SEM – 8**
- 1.4 Considerações ao se candidatar PLS-SEM – 11**
 - 1.4.1 Principais características do PLS-SEM Método – 11

1.4.2 Características dos dados – 15

1.4.3 Características do modelo – 20

**1.5 Diretrizes para escolher
Entre PLS-SEM e
CB-SEM – 22**

Referências – 24

1.1 • O que é modelagem de equações estruturais?

Objetivos de aprendizagem

Depois de ler este capítulo, você deve:

1. Compreender os princípios da modelagem de equações estruturais (MEE)
2. Descreva os elementos básicos de um modelo de equação estrutural
3. Compreender os conceitos básicos da modelagem de equações estruturais de mínimos quadrados parciais (PLS-SEM)
4. Explique as diferenças entre a modelagem de equações estruturais baseada em covariância (CB-SEM) e PLS-SEM e quando usar cada uma das abordagens

1.1 O que é modelagem de equações estruturais?

Técnicas de análise de dados multivariados de primeira geração, como regressão múltipla, regressão logística e análise de variância, pertencem ao conjunto central de métodos estatísticos empregados por pesquisadores para testar empiricamente relações hipotéticas entre variáveis de interesse. Numerosos pesquisadores em várias disciplinas científicas aplicaram esses métodos para gerar descobertas que moldaram significativamente a maneira como vemos o mundo hoje. Essas técnicas têm três limitações importantes em comum, a saber: (1) a postulação de uma estrutura de modelo simples, (2) exigir que todas as variáveis possam ser consideradas observáveis e (3) a suposição de que todas as variáveis são medidas sem erro (Haenlein & Kaplan, 2004).

Com relação à primeira limitação, a análise de regressão múltipla e suas extensões postulam uma estrutura de modelo simples envolvendo uma camada de variáveis dependentes e independentes. Cadeias causais, como “A leva a B leva a C” ou redes nomológicas mais complexas envolvendo um grande número de variáveis intervenientes, só podem ser estimadas por partes com esses métodos, em vez de simultaneamente, o que pode ter consequências severas para a qualidade dos resultados (Sarstedt, Hair, Nitzl, Ringle e Howard, 2020).

Com relação à segunda limitação, métodos do tipo regressão são restritos ao processamento de variáveis observáveis, como idade ou vendas (em unidades ou dólares). Conceitos teóricos, que são “propriedades ou atributos abstratos e não observáveis de uma unidade social ou entidade” (Bagozzi & Philipps, 1982, p. 465), só podem ser considerados após validação autônoma prévia por meio de, por exemplo, uma análise fatorial confirmatória (CFA). A inclusão ex post de medidas de conceitos teóricos, no entanto, vem com várias deficiências.

Com relação à terceira limitação e relacionada ao ponto anterior, é preciso ter em mente que cada observação do mundo real é acompanhada por um certo grau de **erro de medição**, que pode ser sistemático ou aleatório. Técnicas de primeira geração são, estritamente falando, aplicáveis somente quando variáveis medidas não contêm erro sistemático nem aleatório. Essa situação é, no entanto, raramente encontrada na realidade, particularmente quando o objetivo é estimar relações entre medidas de conceitos teóricos. Uma vez que as ciências sociais, e muitos outros campos de investigação científica, rotineiramente lidam com conceitos teóricos, como percepções, atitudes e intenções, essas limitações das técnicas de primeira geração são fundamentais.

1

Para superar essas limitações, os pesquisadores têm se voltado cada vez mais para **técnicas de segunda geração**. Esses métodos, chamados de **modelagem de equações estruturais (SEM)**, permitem que os pesquisadores modelem e estimem simultaneamente relacionamentos complexos entre múltiplas variáveis dependentes e independentes. Os conceitos em consideração são tipicamente não observáveis e medidos indiretamente por múltiplos indicadores. Ao estimar os relacionamentos, o SEM considera o erro de medição em variáveis observadas. Como resultado, o método obtém uma medição mais precisa dos conceitos teóricos de interesse (Cole & Preacher, 2014). Discutiremos esses aspectos nas seções a seguir com mais detalhes.

Dois métodos populares dominam o SEM na prática: **SEM baseado em covariância (CB-SEM)** e **SEM de mínimos quadrados parciais (PLS-SEM)**, também chamado de **modelagem de caminho PLS**. O CB-SEM é usado principalmente para confirmar (ou rejeitar) teorias e suas hipóteses subjacentes. Essa abordagem confirma/rejeita hipóteses determinando o quão próximo um modelo teórico proposto pode reproduzir a matriz de covariância para um conjunto de dados de amostra observado. Em contraste, o PLS foi introduzido como uma abordagem “causal-preditiva” para SEM (Jöreskog & Wold, 1982, p. 270), que se concentra em explicar a variância nas variáveis dependentes do modelo (Chin et al., 2020).

O PLS-SEM está evoluindo rapidamente como uma técnica de modelagem estatística. Nas últimas décadas, houve vários artigos introdutórios sobre essa metodologia (por exemplo, Chin, 1998; Haenlein & Kaplan, 2004; Hair et al., 2020; Hair, Howard, & Nitzl, 2020; Hair, Risher, Sarstedt, & Ringle, 2019; Nitzl & Chin, 2017; Rigdon, 2013; Roldán & Sánchez-Franco, 2012; Tenenhaus, Esposito Vinzi, Chatelin, & Lauro, 2005; Wold, 1985), bem como artigos de revisão examinando como pesquisadores de diferentes disciplinas usaram o método (Tabela 1.1). À luz do crescente amadurecimento do campo, os pesquisadores também começaram a explorar a infraestrutura de conhecimento da pesquisa metodológica sobre PLS-SEM, analisando as estruturas de autores, países e redes de cocitação (Hwang, Sarstedt, Cheah e Ringle, 2020; Khan et al., 2019).

O restante deste capítulo fornece primeiramente uma breve introdução à medição e à teoria estrutural como base para apresentar o método PLS-SEM. Ao descrever as características do método PLS-SEM, também discutimos características distintivas em relação ao CB-SEM. Finalmente, delineamos considerações ao usar o PLS-SEM e destacamos situações que favorecem seu uso em comparação ao CB-SEM.

1.2 Princípios da Modelagem de Equações Estruturais

1.2.1 Modelos de Caminho com Variáveis Latentes

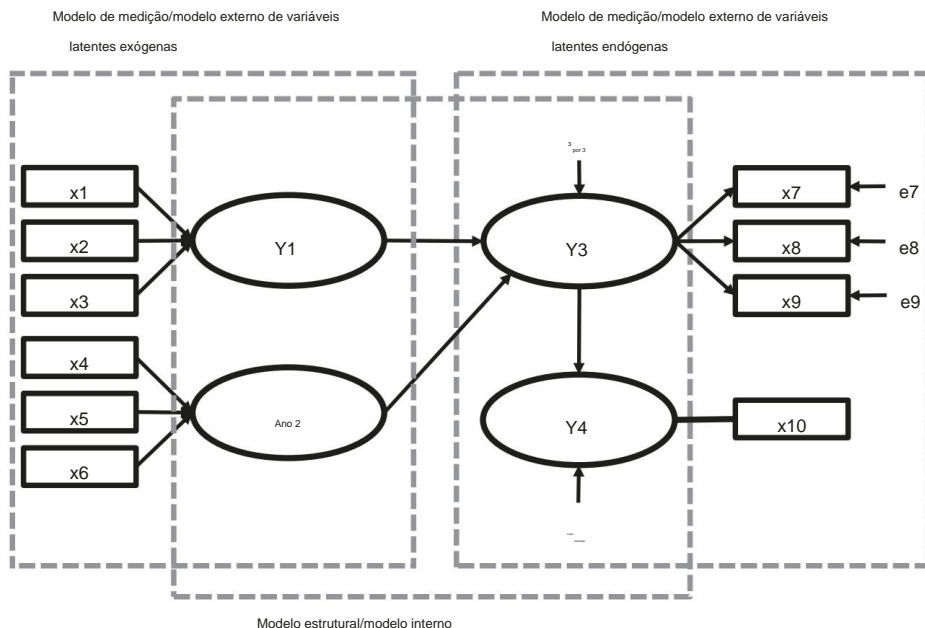
Modelos de caminho são diagramas usados para exibir visualmente as hipóteses e relacionamentos de variáveis que são examinados quando SEM é aplicado (Hair, Page, & Brunsveld, 2020; Hair, Ringle, & Sarstedt, 2011). Um exemplo de um modelo de caminho é mostrado em Fig. 1.1.

Construtos (ou seja, variáveis que não são diretamente mensuráveis), também chamadas de **variáveis latentes**, são representadas em modelos de caminho como círculos ou ovais (Y_1 a Y_4). Os **indicadores**, também chamados de itens ou variáveis manifestas, são as variáveis diretamente medidas.

.. Tabela 1.1 Artigos de revisão sobre o uso do PLS-SEM	
Disciplinas	Referências
Contabilidade	Lee, Petter, Fayard e Robinson (2011) Nitzl (2016)
Gestão de construção	Zeng, Liu, Gong, Hertogh e König (2021)
Empreendedorismo	Manley, Hair, Williams e McDowell (2020)
Empresa familiar	Sarstedt, Ringle, Smith, Reams e Hair (2014)
Ensino superior	Ghasemy, Teeroovengadum, Becker e Ringle, (2020)
Hotelaria e turismo	Ali, Rasoolimanesh, Sarstedt, Ringle e Ryu (2018) do Valle, P. O., e Assaker, G. (2016) Usakli e Kucukergin (2018)
Gestão de recursos humanos	Ringle e outros (2020)
Pesquisa de negócios internacionais	Richter, Sinkovics, Ringle e Schlägel (2016)
Gestão do conhecimento	Cepeda Carrión, Cegarra-Navarro e Cillo (2019)
Gerenciamento	Cabelo, Sarstedt, Pieper e Ringle (2012)
Marketing	Cabelo, Sarstedt, Ringle e Mena (2012)
Sistemas de informação de gestão	Cabelo, Hollingsworth, Randolph e Chong (2017) Ringle e outros (2012)
Gestão de operações	Bayonne, Marin-Garcia e Alfalla-Luque (2020) Peng e Lai (2012)
Psicologia	Willaby, Costa, Burns, MacCann e Roberts (2015)
Engenharia de software	Russo e Stol (2021)
Gestão da cadeia de abastecimento	Kaufmann e Gaeckler (2015)
Fonte: Hair, Hult, Ringle, & Sarstedt (2022), Cap. 1; usado com permissão de Sage	

que contêm os dados brutos. Eles são representados em modelos de caminho como retângulos (x1 a x10). Os relacionamentos entre construções, bem como entre construções e seus indicadores atribuídos, são representados como setas. No PLS-SEM, as setas são sempre de ponta única, representando, portanto, relacionamentos direcionais. Setas de ponta única são consideradas relacionamentos preditivos e, com forte suporte teórico, podem ser interpretadas como relacionamentos causais.

Um modelo de caminho PLS consiste em dois elementos. Primeiro, há um **modelo estrutural** (também chamado de **modelo interno** no contexto do PLS-SEM) que vincula os construtos (círculos ou ovais). O modelo estrutural também exibe os relacionamentos (caminhos) entre os construtos. Em segundo lugar, há os **modelos de medição** (também chamados de **modelos externos** no PLS-SEM) dos construtos que exibem os relacionamentos entre os construtos e as variáveis indicadoras (retângulos). Na **Fig . 1.1**, há dois tipos de modelos de medição: um para o **exógeno**



.. Fig. 1.1 Um modelo de caminho simples. (Fonte: Hair et al., 2022, Cap. 1; usado com permissão de Sage)

variáveis latentes (ou seja, aqueles constructos que apenas explicam outros constructos no modelo) e um para as **variáveis latentes endógenas** (ou seja, aqueles constructos que estão sendo explicados no modelo). Em vez de se referir a modelos de medição de variáveis latentes exógenas e endógenas, os pesquisadores geralmente se referem ao modelo de medição de uma variável latente específica. Por exemplo, x1 a x3 são os indicadores usados no modelo de medição de Y1, enquanto Y4 inclui apenas o indicador x10 no modelo de medição.

Os **termos de erro** (por exemplo, e7 ou e8; . Fig. 1.1) são conectados aos construtos (endógenos) e variáveis medidas (refetivamente) por setas de ponta única. Os termos de erro representam a variância inexplicada quando os modelos de caminho são estimados (ou seja, a diferença entre a previsão dentro da amostra do modelo de um valor e um valor observado de uma variável manifesta ou latente). Os termos de erro e7 a e9 em . Fig. 1.1 são conectados aos indicadores cujos relacionamentos apontam do construto (Y3) para os indicadores (ou seja, indicadores medidos reflexivamente).

Em contraste, os indicadores medidos formativamente x1 a x6, onde a relação vai do indicador para o construto (Y1 e Y2), não têm termos de erro (Sarstedt, Hair, Ringle, Thiele e Gudergan, 2016). Finalmente, para o construto de item único Y4, a direção das relações entre o construto e o indicador não é relevante, pois o construto e o item são equivalentes. Pelo mesmo motivo, não há termo de erro conectado a x10. O modelo estrutural também contém termos de erro. Na Fig. 1.1, z3 e z4 são associados às variáveis latentes endógenas Y3 e Y4 (observe que os termos de erro em construtos e variáveis medidas são rotulados de forma diferente). Em contraste, as variáveis latentes exógenas (Y1 e Y2) que apenas explicam

outras variáveis latentes no modelo estrutural não têm um termo de erro, independentemente de serem especificadas reflexivamente ou formativamente.

1.2.2 Testando relacionamentos teóricos

Modelos de caminho são desenvolvidos com base na teoria e são frequentemente usados para testar relacionamentos teóricos. **Teoria** é um conjunto de hipóteses sistematicamente relacionadas desenvolvidas seguindo o método científico que pode ser usado para explicar e prever resultados. Assim, hipóteses são conjecturas individuais, enquanto teorias são múltiplas hipóteses que são logicamente ligadas entre si e podem ser testadas empiricamente. Dois tipos de teoria são necessários para desenvolver modelos de caminho: teoria de medição e teoria estrutural. A teoria de medição especifica quais indicadores e como eles são usados para medir um certo conceito teórico. Em contraste, a teoria estrutural especifica como os construtos são relacionados uns aos outros no modelo estrutural.

Testar a teoria usando PLS-SEM segue um processo de duas etapas (Hair, Black, Babin e Anderson, 2019). Primeiro testamos a teoria de medição para confirmar a confiabilidade e validade dos modelos de medição. Depois que os modelos de medição são confirmados, passamos a testar a teoria estrutural. A lógica é que devemos primeiro confirmar a teoria de medição antes de testar a teoria estrutural, porque a teoria estrutural não pode ser confirmada se as medidas não forem confiáveis ou inválidas.

1.2.3 Teoria da Medição

A teoria da medição especifica como as variáveis latentes (construtos) são medidas.

Geralmente, há duas maneiras diferentes de medir variáveis não observáveis. Uma abordagem é chamada de medição reflexiva, e a outra é medição formativa. Os construtos Y1 e Y2 em Fig. 1.1 são modelados com base em um **modelo de medição formativa**. Observe que as setas direcionais estão apontando das variáveis indicadoras (x_1 a x_3 para Y1 e x_4 a x_6 para Y2) para o construto, indicando uma relação preditiva (causal) nessa direção.

Em contraste, Y3 em Fig. 1.1 é modelada com base em um **modelo de medição reflexivo**. Com indicadores reflexivos, a direção das setas é do construto para as variáveis indicadoras, indicando a suposição de que o construto “causa” a medição (mais precisamente, a covariação) das variáveis indicadoras. Conforme indicado em Fig. 1.1, as medidas reflexivas têm um termo de erro associado a cada indicador, o que não é o caso com medidas formativas. As últimas são consideradas livres de erros (Diamantopoulos, 2006). Finalmente, observe que Y4 é medido usando um único item em vez de medidas de vários itens. Portanto, a relação entre construto e indicador não é direcionada.

Decidir se deve medir os construtos de forma reflexiva ou formativa e se deve usar vários itens ou uma medida de item único é fundamental ao desenvolver modelos de caminho. Hair, Hult, Ringle e Sarstedt (2022; Cap. 2) explicam essas abordagens para modelar construtos em mais detalhes.

1

1.2.4 Teoria Estrutural

A **teoria estrutural** mostra como as variáveis latentes estão relacionadas entre si (ou seja, mostra os construtos e suas relações de caminho no modelo estrutural). A localização e a sequência dos construtos são baseadas na teoria ou na experiência e no conhecimento acumulado do pesquisador ou em ambos. Quando os modelos de caminho são desenvolvidos, a sequência é da esquerda para a direita. As variáveis no lado esquerdo do modelo de caminho são variáveis independentes, e qualquer variável no lado direito é uma variável dependente. Além disso, as variáveis à esquerda são mostradas como precedendo sequencialmente e prevendo as variáveis à direita. No entanto, quando as variáveis estão no meio do modelo de caminho (entre as variáveis que servem apenas como variáveis independentes ou dependentes – Y_3 ; - Fig. 1.1), elas servem como variáveis independentes e dependentes no modelo estrutural.

Quando variáveis latentes servem apenas como variáveis independentes, elas são chamadas de variáveis latentes exógenas (Y_1 e Y_2). Quando variáveis latentes servem apenas como variáveis dependentes (Y_4) ou como variáveis independentes e dependentes (Y_3), elas são chamadas de variáveis latentes endógenas (Fig. 1.1). Qualquer variável latente que tenha apenas setas de uma ponta saindo dela é uma variável latente exógena. Em contraste, variáveis latentes endógenas podem ter setas de uma ponta entrando e saindo delas (Y_3) ou somente entrando nelas (Y_4). Observe que as variáveis latentes exógenas Y_1 e Y_2 não têm termos de erro, uma vez que essas construções são as entidades (variáveis independentes) que estão explicando as variáveis dependentes no modelo de caminho.

1.3 PLS-SEM e CB-SEM

Existem duas abordagens principais para estimar as relações em um modelo de equação estrutural (Hair et al., 2011; Hair, Black, et al., 2019). Uma é CB-SEM, e a outra é PLS-SEM, sendo esta última o foco deste livro. Cada uma é apropriada para um contexto de pesquisa diferente, e os pesquisadores precisam entender as diferenças para aplicar o método correto (Marcoulides & Chin, 2013; Rigdon, Sarstedt, & Ringle, 2017). Finalmente, alguns pesquisadores têm defendido o uso de regressões baseadas em pontuações de soma, em vez de algum tipo de ponderação de indicadores como é feito pelo PLS-SEM. A abordagem de pontuações de soma praticamente não oferece valor em comparação com a abordagem ponderada PLS-SEM e, de fato, pode produzir resultados errôneos (Hair et al., 2017). Por esse motivo, nas seções a seguir, discutiremos apenas brevemente as pontuações de soma e, em vez disso, nos concentraremos nos métodos PLS-SEM e CB-SEM.

Uma diferença conceitual crucial entre PLS-SEM e CB-SEM está relacionada à maneira como cada método trata as variáveis latentes incluídas no modelo. CB-SEM representa um **método SEM baseado em fatores comuns** que considera os construtos como fatores comuns que explicam a covariação entre seus indicadores associados. Essa abordagem é consistente com a filosofia de medição subjacente à medição reflexiva, na qual os indicadores e suas covariações são considerados manifestações do construto subjacente. Em princípio, CB-SEM também pode acomodar modelos de medição formativos, embora o método siga um modelo comum

1.3 • PLS-SEM e CB-SEM

abordagem de estimativa de modelo de fator. Para estimar esse tipo de modelo, no entanto, os pesquisadores devem seguir regras que exigem restrições específicas no modelo para garantir a identificação do modelo (Bollen & Davies, 2009; Diamantopoulos & Riefler, 2011), o que significa que o método pode calcular estimativas para todos os parâmetros do modelo. Como Hair, Sarstedt, Ringle e Mena (2012, p. 420) observam, “[e]ssas restrições frequentemente contradizem considerações teóricas, e surge a questão se o design do modelo deve guiar a teoria ou vice-versa”.

O PLS-SEM, por outro lado, assume que os conceitos de interesse podem ser medidos como compostos (Jöreskog & Wold, 1982), razão pela qual o PLS é considerado um método **SEM baseado em compostos** (Hwang et al., 2020). A estimativa do modelo no PLS-SEM envolve a combinação linear dos indicadores de um modelo de medição para formar variáveis compostas. As variáveis compostas são consideradas representações abrangentes dos construtos e, portanto, proxies válidos das variáveis conceituais que estão sendo examinadas (por exemplo, Hair & Sarstedt, 2019). A abordagem baseada em compostos é consistente com a filosofia de medição subjacente à medição formativa, mas isso não implica que o PLS-SEM seja capaz apenas de estimar construtos especificados formativamente. A razão é que a perspectiva de estimativa (ou seja, formar compostos para representar variáveis conceituais) não deve ser confundida com a perspectiva da teoria da medição (ou seja, especificar modelos de medição como reflexivos ou formativos). A maneira como um método como o PLS-SEM estima os parâmetros do modelo precisa ser claramente distinguida de quaisquer considerações teóricas de medição sobre como operacionalizar construções (Sarstedt et al., 2016).

Os pesquisadores podem incluir modelos de medição especificados de forma reflexiva e formativa que o PLS-SEM pode estimar diretamente.

Ao seguir uma abordagem baseada em compostos para SEM, o PLS relaxa a forte suposição do CB-SEM de que toda a covariação entre os conjuntos de indicadores é explicada por um fator comum (Henseler et al., 2014; Rigdon, 2012; Rigdon et al., 2014). Ao mesmo tempo, usar compostos ponderados de variáveis indicadoras facilita a contabilização do erro de medição, tornando o PLS-SEM superior em comparação à regressão múltipla usando **pontuações de soma**, onde cada indicador é ponderado igualmente.

É importante notar que os compostos produzidos pelo PLS-SEM não são assumidos como idênticos aos conceitos teóricos que eles representam. Eles são explicitamente reconhecidos como aproximações (Rigdon, 2012). Como consequência, alguns estudiosos veem o CB-SEM como um método mais direto e preciso para medir empiricamente conceitos teóricos (por exemplo, Rönkkö, McIntosh e Antonakis, 2015), enquanto o PLS-SEM fornece aproximações. Outros estudiosos argumentam, no entanto, que tal visão é bastante míope, uma vez que fatores comuns derivados no CB-SEM também não são necessariamente equivalentes aos conceitos teóricos que são o foco da pesquisa (Rigdon, 2012; Rigdon et al., 2017; Rossiter, 2011; Sarstedt et al., 2016). Rigdon, Becker e Sarstedt (2019a) mostram que modelos de fatores comuns podem estar sujeitos a graus consideráveis de incerteza metrológica. **A incerteza metrológica** se refere à dispersão dos valores de medição que podem ser atribuídos ao objeto ou conceito que está sendo medido (JCGM/WG1, 2008). Numerosas fontes contribuem para a incerteza metrológica, como incerteza definicional ou limitações relacionadas ao design da escala de medição, que vão muito além dos simples erros-padrão

1

produzido por análises CB-SEM (Hair & Sarstedt, 2019). Como tal, a incerteza é uma ameaça à validade da medição e tem consequências adversas para a replicabilidade dos resultados do estudo (Rigdon, Sarstedt, & Becker, 2020). Embora a incerteza também se aplique ao SEM baseado em compósitos, a maneira como os pesquisadores tratam os modelos em análises CB-SEM normalmente leva a um aumento pronunciado na incerteza (Rigdon & Sarstedt, 2021). Mais precisamente, em um esforço para melhorar o desempenho do modelo, os pesquisadores normalmente reduzem o número de indicadores por construto, o que por sua vez aumenta a incerteza (Hair, Matthews, Matthews, & Sarstedt, 2017; Rigdon et al., 2019a). Essas questões não implicam necessariamente que os modelos compostos sejam superiores, mas lançam dúvidas consideráveis sobre a suposição de alguns pesquisadores de que o CB-SEM constitui o padrão ouro ao medir conceitos não observáveis. Na verdade, pesquisadores em vários campos da ciência mostram uma apreciação crescente de que fatores comuns podem nem sempre ser a abordagem correta para medir conceitos (por exemplo, Rhemtulla, van Bork e Borsboom, 2020; Rigdon, 2016). Da mesma forma, Rigdon, Becker e Sarstedt (2019b) mostram que usar pontuações de soma pode aumentar significativamente o grau de incerteza metrológica, o que questiona essa prática de medição.

Além das diferenças na filosofia de medição, o tratamento diferenciado de variáveis latentes e, mais especificamente, a disponibilidade de **pontuações de construto** também têm consequências para as áreas de aplicação dos métodos. Especificamente, embora seja possível estimar pontuações de variáveis latentes dentro de uma estrutura CB-SEM, essas pontuações estimadas não são únicas. Ou seja, um número infinito de conjuntos diferentes de pontuações de variáveis latentes que se encaixarão igualmente bem no modelo são possíveis. Uma consequência crucial dessa **indeterminação do fator (pontuação)** é que as correlações entre um fator comum e qualquer variável fora do modelo fatorial são elas próprias indeterminadas (Guttman, 1955). Ou seja, elas podem ser altas ou baixas, dependendo de qual conjunto de pontuações fatoriais alguém escolher. Como resultado, essa limitação torna o CB-SEM grosseiramente inadequado para **predição** (por exemplo, Dijkstra, 2014; Hair & Sarstedt, 2021). Em contraste, uma grande vantagem do PLS-SEM é que ele sempre produz uma única pontuação específica (ou seja, determinada) para cada composto de cada observação, uma vez que os pesos/carregamentos do indicador são estabelecidos. Essas pontuações determinadas são proxies dos conceitos teóricos que estão sendo medidos, assim como os fatores são proxies para as variáveis conceituais no CB-SEM (Rigdon et al., 2017; Sarstedt et al., 2016).

Usando esses proxies como entrada, o PLS-SEM aplica regressão de mínimos quadrados ordinários com o objetivo de minimizar os termos de erro (ou seja, a variância residual) dos construtos endógenos. Em suma, o PLS-SEM estima coeficientes (ou seja, relacionamentos do modelo de caminho) com o objetivo de maximizar os valores de R² dos construtos endógenos (alvo). Esse recurso atinge o objetivo de previsão (na amostra) do PLS-SEM (Hair & Sarstedt, 2021), que é, portanto, o método preferido quando o objetivo da pesquisa é o desenvolvimento da teoria e a explicação da variância (previsão dos construtos). Por esse motivo, o PLS-SEM também é considerado uma **abordagem SEM baseada em variância**. Especificamente, a lógica da abordagem PLS-SEM é que toda a variância dos indicadores deve ser usada para estimar os relacionamentos do modelo, com foco particular na previsão das variáveis dependentes (por exemplo, McDonald, 1996).

Em contraste, o CB-SEM divide a variância total em três tipos – variância comum, única e de erro – mas utiliza apenas a variância comum (ou seja, a variância compartilhada

com outros indicadores no mesmo modelo de medição) para a estimativa do modelo (Hair, Black, et al., 2019). Ou seja, o CB-SEM apenas explica a covariação entre os indicadores de medição e do modelo estrutural (Jöreskog, 1973) e não se concentra na previsão de variáveis dependentes (Hair, Matthews, et al., 2017).

!Atenção

O PLS-SEM é semelhante, mas não equivalente, à **regressão PLS**, outra técnica popular de análise de dados multivariados (Abdi, 2010; Wold, Sjöström e Eriksson, 2001). A regressão PLS é uma abordagem baseada em regressão que explora as relações lineares entre múltiplas variáveis independentes e uma ou várias variáveis dependentes. A regressão PLS difere da regressão regular, no entanto, porque, no desenvolvimento do modelo de regressão, o método deriva fatores compostos das múltiplas variáveis independentes por meio da análise de componentes principais. A PLS-SEM, por outro lado, depende de redes pré-especificadas de relações entre construtos, bem como entre construtos e suas medidas (veja Mateos-Aparicio, 2011, para uma comparação mais detalhada entre PLS-SEM e regressão PLS).

1.4 Considerações ao aplicar PLS-SEM

1.4.1 Principais características do método PLS-SEM

Várias considerações são importantes ao decidir se deve ou não aplicar PLS-SEM. Essas considerações também têm suas raízes nas características do método.

As propriedades estatísticas do algoritmo PLS-SEM têm características importantes associadas às características dos dados e do modelo usados. Além disso, as propriedades do método PLS-SEM afetam a avaliação dos resultados. Quatro questões críticas são relevantes para a aplicação do PLS-SEM (Hair et al., 2011; Hair, Risher, et al., 2019): (1) características dos dados, (2) características do modelo, (3) estimativa do modelo e (4) avaliação do modelo. A Tabela 1.2 resume as principais características do método PLS-SEM. Uma visão geral inicial dessas questões é fornecida neste capítulo. Para uma explicação mais detalhada, consulte Hair et al.

O PLS-SEM funciona eficientemente com tamanhos de amostra pequenos e modelos complexos (Cassel, Hackl e Westlund, 1999; Hair, Sarstedt e Ringle, 2019). Além disso, diferente do CB-SEM baseado em máxima verossimilhança, que requer dados normalmente distribuídos, o PLS-SEM não faz suposições distribucionais (ou seja, não é paramétrico). O PLS-SEM pode facilmente lidar com modelos de medição reflexivos e formativos, bem como construções de itens únicos, sem problemas de identificação. Portanto, pode ser aplicado em uma ampla variedade de situações de pesquisa. Ao aplicar o PLS-SEM, os pesquisadores também se beneficiam da alta eficiência na estimativa de parâmetros, que se manifesta no maior **poder estatístico** do método em comparação ao do CB-SEM. Maior poder estatístico significa que o PLS-SEM tem mais probabilidade de tornar um relacionamento específico significativo quando ele está de fato presente na população. O mesmo vale para a comparação com a regressão usando dados de pontuação de soma, que também é caracterizada por menor poder estatístico do que o PLS-SEM (Hair, Hollingsworth, et al., 2017).

.. Tabela 1.2 Principais características do PLS-SEM

Características dos dados	
Tamanho da amostra	Sem problemas de identificação com tamanhos de amostra pequenos Alcança altos níveis de poder estatístico com tamanhos de amostra pequenos Tamanhos de amostra maiores aumentam a precisão (ou seja, consistência) das estimativas PLS-SEM
Distribuição	Sem suposições distributivas; PLS-SEM é um método não paramétrico Valores discrepantes influentes e colinearidade podem influenciar os resultados
Valores ausentes	Altamente robusto, desde que os valores ausentes estejam abaixo de um nível razoável (menos de 5%)
Escala de medida-mento	Trabalha com dados métricos e variáveis escalonadas quase métricas (ordinais) O algoritmo padrão PLS-SEM acomoda variáveis codificadas em binário, mas considerações adicionais são necessárias quando elas são usadas como variáveis de controle e moderadoras e na análise de dados de experimentos de escolha discreta
Características do modelo	
Número de itens em cada construção modelo de medição	Lida com construções medidas com medidas de itens únicos e múltiplos
Relações entre construções e seus indicadores	Incorpora facilmente modelos de medição reflexivos e formativos
Complexidade do modelo	Lida com modelos complexos com muitos relacionamentos de modelos estruturais
Configuração do modelo	Nenhum loop causal (nenhum relacionamento circular) é permitido no modelo estrutural
Estimativa do modelo	
Objetivo	Visa maximizar a quantidade de variância inexplicada nas medidas dependentes (ou seja, os valores R2)
Eficiência	Converge após algumas iterações (mesmo em situações com modelos complexos e/ou grandes conjuntos de dados) para a solução ótima (ou seja, o algoritmo é muito eficiente)
Natureza de construções	Vistos como proxies do conceito latente sob investigação, representados por compósitos
Construir pontuações	Estimados como combinações lineares de seus indicadores (ou seja, são determinados) Usado para fins preditivos Pode ser usado como entrada para análises subsequentes Não afetado por limitações e inadequações de dados
Estimativas de parâmetros	As relações do modelo estrutural são geralmente subestimadas e as relações do modelo de medição são geralmente superestimadas em comparação com soluções obtidas usando dados de modelos de fatores comuns Imparcial e consistente ao estimar dados de modelos compostos Altos níveis de poder estatístico em comparação com métodos alternativos, como CB-SEM e regressão múltipla com pontuações de soma

.. Tabela 1.2 (continuação)	
Avaliação do modelo	
Avaliação do modelo geral	O conceito de ft – conforme definido no CB-SEM – não se aplica ao PLS-SEM. Os esforços para introduzir medidas de ft modelo geralmente não tiveram sucesso
Avaliação do medição modelos	Os modelos de medição reflexivos são avaliados com base na confiabilidade do indicador, confiabilidade da consistência interna, validade convergente e validade discriminante. Os modelos de medição formativa são avaliados com base na validade convergente, na colinearidade do indicador e na significância e relevância dos pesos do indicador.
Avaliação do modelo estrutural	Colinearidade entre conjuntos de construções preditivas Significado e relevância dos coeficientes de caminho Critérios disponíveis para avaliar o poder dentro da amostra (ou seja, explicativo) e o poder preditivo fora da amostra (PLSpredict) do modelo
Análises adicionais	A pesquisa metodológica ampliou substancialmente o original Método PLS-SEM introduzindo procedimentos avançados de modelagem, avaliação e análise. Alguns exemplos incluem: Análise de tétrades confirmatória Análise composta confirmatória Modelagem de escolha discreta Avaliação de endogeneidade Construções de ordem superior Análise de classe latente Invariância do modelo de medição Análise de mediação Seleção de modelo Efeitos moderadores, incluindo mediação moderada Análise multigrupo Análise de condições necessárias Efeitos não lineares
Fonte: Adaptado e ampliado de Hair et al. (2011). Copyright © 2011 por ME Sharpe, Inc. Reproduzido com permissão do editor (Taylor & Francis Ltd., 7 http://www.tandfonline.com)	

Existem, no entanto, várias limitações do PLS-SEM. Em sua forma básica, a técnica não pode ser aplicada quando modelos estruturais contêm loops causais ou relacionamentos circulares entre as variáveis latentes (ou seja, modelos não recursivos). Extensões iniciais do algoritmo básico PLS-SEM que ainda não foram implementadas em pacotes de software PLS-SEM padrão, no entanto, permitem o manuseio de relacionamentos circulares (Lohmöller, 1989). Além disso, como o PLS-SEM não tem uma medida global estabelecida de bondade de ft, seu uso para teste e confirmação de teoria é mais limitado em certas situações. Pesquisas recentes tentaram promover medidas comuns de bondade de ft dentro de uma estrutura PLS-SEM (Schuberth, Henseler e Dijkstra, 2018), mas com sucesso muito limitado. O conceito de modelo ft — conforme definido no CB-SEM — não é aplicável ao PLS-SEM devido a

1

diferentes princípios de funcionamento (Hair, Sarstedt e Ringle, 2019). Em vez disso, a estimativa e avaliação de modelos baseados em PLS-SEM seguem um paradigma causal-preditivo, no qual o objetivo é testar o poder preditivo de um modelo, derivado da teoria e da lógica. Como tal, o método atinge um equilíbrio entre métodos de aprendizado de máquina, que são totalmente preditivos por natureza, e CB-SEM, que se concentra na confirmação e no ajuste do modelo (Richter, Cepeda Carrión, Roldán e Ringle, 2016). Sua natureza causal-preditiva torna o PLS-SEM particularmente atraente para pesquisas em campos que visam derivar recomendações para a prática. Por exemplo, recomendações em seções de implicação gerencial em periódicos de pesquisa empresarial sempre incluem declarações preditivas (“nossos resultados sugerem que os gerentes devem...”). Fazer tais declarações requer um foco de previsão na estimativa e avaliação do modelo (Sarstedt e Danks, 2021). O PLS-SEM enfatiza perfeitamente essa necessidade, pois o método esclarece os mecanismos (ou seja, as relações do modelo estrutural) por meio dos quais as previsões são geradas (Hair, 2020; Hair & Sarstedt, 2019, 2021).

Em escritos iniciais, pesquisadores notaram que a estimativa PLS é “deliberadamente aproximada” do SEM baseado em fatores (Hui & Wold, 1982, p. 127), uma característica anteriormente referida como **viés PLS-SEM** (por exemplo, Chin, Marcolin, & Newsted, 2003). Vários estudos usaram simulações para demonstrar o suposto viés PLS-SEM (por exemplo, Goodhue, Lewis, & Thompson, 2012; McDonald, 1996; Rönkkö & Evermann, 2013). De acordo com pesquisas anteriores sobre o viés PLS-SEM, as estimativas do modelo de medição são enviesadas para cima, enquanto as estimativas do modelo estrutural são enviesadas para baixo em comparação com os resultados CB-SEM. Os estudos concluem que as estimativas de parâmetros se aproximarão do que foi rotulado como valores de parâmetros “verdadeiros” quando tanto o número de indicadores por construto quanto o tamanho da amostra aumentam (Hui & Wold, 1982).

No entanto, todos os estudos de simulação acima mencionados usaram CB-SEM como referência contra a qual as estimativas PLS-SEM foram avaliadas com a suposição de que deveriam ser as mesmas. Como PLS-SEM é uma abordagem baseada em compósitos, que usa a variância total para estimar parâmetros, diferenças podem ser esperadas em tal avaliação (Lohmöller, 1989; Schneeweiß, 1991). Não surpreendentemente, os mesmos problemas se aplicam quando modelos compostos são usados para estimar resultados CB-SEM. Na verdade, Sarstedt et al. (2016) mostram que o viés produzido por CB-SEM é muito mais severo do que o de PLS-SEM, ao aplicar o método ao tipo errado de modelo (ou seja, estimar modelos compostos com CB-SEM versus estimar modelos de fator comum com PLS-SEM). Além dessas preocupações conceituais, estudos de simulação mostram que as diferenças entre as estimativas PLS-SEM e CB-SEM, ao assumir a última como um padrão de comparação, são muito pequenas, desde que os modelos de medição atendam aos padrões mínimos recomendados em termos de qualidade de medição (ou seja, confiabilidade e validade). Especificamente, quando os modelos de medição têm quatro ou mais indicadores e as cargas dos indicadores atendem aos padrões comuns ($\gamma \geq 0,70$), praticamente não há diferenças entre os dois métodos em termos de precisão dos parâmetros (por exemplo, Reinartz, Haenlein e Henseler, 2009; Sarstedt et al., 2016). Assim, o viés PLS-SEM amplamente discutido não tem relevância prática para a grande maioria das aplicações (por exemplo, Binz Astrachan, Patel e Wanzenried, 2014).

Finalmente, a pesquisa metodológica ampliou substancialmente o PLS original. Método SEM introduzindo procedimentos avançados de modelagem, avaliação e análise

1.4 · Considerações ao aplicar PLS-SEM

dures. Exemplos incluem diferentes tipos de verificações de robustez (Sarstedt et al., 2020), construções de ordem superior (Sarstedt, Hair, Cheah, Becker e Ringle, 2019), modelagem de escolha discreta (Hair, Sarstedt e Ringle, 2019), análise de condição necessária e métodos relacionados (Rasoolimanesh, Ringle, Sarstedt e Olya, 2021; Richter, Schubring, Hauff, Ringle e Sarstedt, 2020) e métricas de previsão fora da amostra (Hair, 2020). Hair, Sarstedt, Ringle e Gudergan (2018) oferecem uma introdução a vários desses tópicos avançados.

A seguir, discutiremos aspectos relacionados às características dos dados (por exemplo, requisitos de tamanho mínimo da amostra) e às características do modelo (por exemplo, complexidade do modelo).

1.4.2 Características dos dados

Características de dados, como requisitos mínimos de tamanho de amostra, dados não normais e escalas de medição (ou seja, o uso de diferentes tipos de escala), estão entre os motivos mais frequentemente declarados para aplicar PLS-SEM em várias disciplinas (por exemplo, Ghasemy, Teeroovengadam, Becker e Ringle, 2020; Hair, Sarstedt, Ringle e Mena, 2012; Ringle et al., 2020). Embora alguns dos argumentos sejam consistentes com as capacidades do método, outros não são. Nas seções a seguir, discutimos essas e também aspectos relacionados às características dos dados.

1.4.2.1 Requisitos mínimos de tamanho de amostra

O tamanho pequeno da amostra é provavelmente o motivo mais frequentemente abusado para o uso do PLS-SEM, com alguns pesquisadores obtendo soluções de modelo com tamanhos de amostra inaceitavelmente baixos (Goodhue et al., 2012; Marcoulides & Saunders, 2006). Esses pesquisadores muitas vezes acreditam que há alguma "mágica" na abordagem PLS-SEM que lhes permite usar uma amostra muito pequena para obter resultados que representam os efeitos que existem em grandes populações de vários milhões de elementos ou indivíduos. Nenhuma técnica de análise multivariada, incluindo PLS-SEM, tem esse tipo de capacidade inferencial "mágica" (Petter, 2018).

O PLS-SEM certamente pode obter soluções com amostras menores, mas a natureza da população determina as situações em que tamanhos de amostra pequenos são aceitáveis (Rigdon, 2016). Por exemplo, em pesquisas business-to-business, as populações são frequentemente restritas em tamanho. Assumindo que outras características situacionais são iguais, quanto mais heterogênea a população, maior o tamanho da amostra necessário para atingir uma precisão aceitável (Cochran, 1977). Se as diretrizes básicas da teoria de amostragem não forem consideradas (Sarstedt, Bengart, Shaltoni e Lehmann, 2018), resultados questionáveis são produzidos.

Além disso, ao aplicar técnicas de análise multivariada, a dimensão técnica do tamanho da amostra se torna relevante. Adirir às diretrizes de tamanho mínimo de amostra garante que os resultados de um método estatístico, como PLS-SEM, tenham poder estatístico adequado. Nesse sentido, uma análise baseada em um tamanho de amostra insuficiente pode não revelar um efeito que existe na população subjacente (o que resulta em cometer um erro do tipo II). Além disso, executar análises estatísticas baseadas em diretrizes de tamanho mínimo de amostra garantirá que os resultados do método estatístico sejam robustos e que o modelo seja generalizável para outra amostra daquela

1

mesma população. Assim, um tamanho de amostra insuficiente pode levar a resultados PLS-SEM que diferem daqueles de outra amostra maior. A seguir, focamos no método PLS-SEM e seus requisitos técnicos de tamanho mínimo de amostra.

A complexidade geral de um modelo estrutural tem pouca influência nos **requisitos de tamanho mínimo de amostra** para PLS-SEM. O motivo é que o algoritmo PLS-SEM não calcula todos os relacionamentos no modelo estrutural ao mesmo tempo. Em vez disso, ele usa regressões de mínimos quadrados ordinários para estimar os relacionamentos de regressão parcial do modelo. Dois estudos iniciais avaliaram sistematicamente o desempenho do PLS-SEM com tamanhos de amostra pequenos e concluíram que o método teve um bom desempenho (por exemplo, Chin & Newsted, 1999; Hui & Wold, 1982). Mais recentemente, estudos de simulação de Hair et al. (2017) e Reinartz et al. (2009) indicam que o PLS-SEM é o método de escolha quando o tamanho da amostra é pequeno. Além disso, em comparação com sua contraparte baseada em covariância, o PLS-SEM tem níveis mais altos de poder estatístico em situações com estruturas de modelo complexas e tamanhos de amostra menores. Da mesma forma, Henseler et al. (2014) mostram que resultados podem ser obtidos com PLS-SEM quando outros métodos não convergem ou fornecem soluções inadmissíveis. Por exemplo, problemas são frequentemente encontrados ao usar CB-SEM em modelos complexos, especialmente quando o tamanho da amostra é limitado. Finalmente, CB-SEM encontra problemas de identificação e convergência quando medidas formativas estão envolvidas (por exemplo, Diamantopoulos & Riefler, 2011).

Infelizmente, alguns pesquisadores acreditam que as considerações sobre o tamanho da amostra não desempenham um papel na aplicação do PLS-SEM. Essa ideia foi fomentada pela regra frequentemente citada de 10 vezes (Barclay, Higgins e Thompson, 1995), que sugere que o tamanho da amostra deve ser igual a 10 vezes o número de variáveis independentes na regressão mais complexa no modelo de caminho PLS (ou seja, considerando modelos de medição e estruturais). Essa regra prática é equivalente a dizer que o tamanho mínimo da amostra deve ser 10 vezes o número máximo de pontas de seta apontando para uma variável latente em qualquer lugar no modelo de caminho PLS. Embora essa regra ofereça uma diretriz aproximada, o requisito de tamanho mínimo da amostra deve considerar o poder estatístico das estimativas. Para avaliar o poder estatístico, os pesquisadores podem considerar tabelas de poder (Cohen, 1992) ou análises de poder usando programas, como G*Power (Faul, Erdfelder, Buchner e Lang, 2009), que está disponível gratuitamente em www.gpower.hhu.de/. Essas abordagens não consideram explicitamente o modelo inteiro, mas, em vez disso, usam a regressão mais complexa nos modelos de medição (formativos) e no modelo estrutural de um modelo de caminho PLS como um ponto de referência para avaliar o poder estatístico. Ao fazer isso, os pesquisadores normalmente visam atingir um nível de poder de 80%. No entanto, o tamanho mínimo da amostra resultante desses cálculos ainda pode ser muito pequeno (Kock & Hadaya, 2018).

Abordando essas preocupações, Kock e Hadaya (2018) propuseram o **método da raiz quadrada inversa**, que considera a probabilidade de que a razão de um coeficiente de caminho e seu erro padrão seja maior que o valor crítico de uma estatística de teste para um nível de significância específico. Os resultados dependem, portanto, de apenas um coeficiente de caminho e não dependem nem do tamanho da regressão mais complexa nos modelos (formativos) nem do tamanho do modelo geral. Assumindo um nível de poder comum de 80% e níveis de significância de 1%, 5% e 10%, a amostra mínima

1.4 • Considerações ao aplicar PLS-SEM

O tamanho da partícula (n_{\min}) é dado pelas seguintes equações, respectivamente, onde p_{\min} é o valor do coeficiente de caminho com a magnitude mínima no modelo de caminho PLS:

$$\text{Nível de significância} = 1\%: n_{\min} > \frac{3.168}{p_{\min}^2}.$$

$$\text{Nível de significância} = 5\%: n_{\min} > \frac{2.486}{p_{\min}^2}.$$

$$\text{Nível de significância} = 10\%: n_{\min} > \frac{2.123}{p_{\min}^2}.$$

Por exemplo, assumindo um nível de significância de 5% e um coeficiente de caminho mínimo eficiente de 0,2, o tamanho mínimo da amostra é dado por

$$n_{\min} > \frac{2.486}{0.2^2} = 154.505.$$

Este resultado precisa ser arredondado para o próximo inteiro, então o tamanho mínimo da amostra é 155.

O método da raiz quadrada inversa é bastante conservador, pois superestima ligeiramente o tamanho da amostra necessário para tornar um efeito significativo em um dado nível de potência. Mais importante, o método é caracterizado por sua facilidade de uso, pois pode ser prontamente implementado.

No entanto, duas considerações são importantes ao usar o método da raiz quadrada inversa. Primeiro, ao usar o menor coeficiente de caminho estatístico como ponto de referência, o método pode ser enganoso, pois os pesquisadores não esperam que os efeitos marginais sejam significativos. Por exemplo, assumir um nível de significância de 5% e um coeficiente de caminho mínimo de 0,01 exigiria um tamanho de amostra de 61.802! Portanto, os pesquisadores devem escolher um coeficiente de caminho mais alto como entrada, dependendo se o modelo produz efeitos gerais fracos ou fortes ou o menor efeito relevante (a ser detectado).

Em segundo lugar, ao confiar em estimativas de modelo, o método da raiz quadrada inversa segue uma abordagem retrospectiva. Como resultado, essa abordagem de avaliação pode ser usada como base para coleta de dados adicionais ou ajustes no modelo. Se possível, no entanto, os pesquisadores devem seguir uma abordagem prospectiva tentando derivar o tamanho mínimo do efeito esperado antes da análise de dados. Para fazer isso, os pesquisadores podem recorrer a pesquisas anteriores envolvendo um histórico conceitual comparável ou modelos com complexidade semelhante ou, preferencialmente, os resultados de um estudo piloto, que testou o modelo hipotético usando uma amostra menor de entrevistados da mesma população. Por exemplo, se o estudo piloto produziu um coeficiente de caminho mínimo de 0,15, esse valor deve ser escolhido como entrada para calcular o tamanho de amostra necessário para o estudo principal.

1

.. **Tabela 1.3** Tamanhos mínimos de amostra para diferentes níveis de coeficientes de caminho mínimo (pmin) e uma potência de 80%

pmin	Nível de significância		
	1%	5%	10%
0,05–0,1	1004	619	451
0,11–0,2	251	155	113
0,21–0,3	112	69	51
0,31–0,4	63	39	29
0,41–0,5	41	25	19

Fonte: Hair et al. (2022), Cap. 1; usado com permissão de Sage

Na maioria dos casos, no entanto, os pesquisadores têm apenas informações limitadas sobre os tamanhos de efeito esperados, mesmo que um estudo piloto tenha sido conduzido. Portanto, é razoável considerar intervalos de tamanhos de efeito em vez de valores específicos para determinar o tamanho da amostra necessário para um estudo específico. A Tabela 1.3 mostra o requisito de tamanho mínimo da amostra para diferentes níveis de significância e intervalos variáveis de pmin. Ao derivar o tamanho mínimo da amostra, é razoável considerar o limite superior do intervalo de efeito como referência, uma vez que o método da raiz quadrada inversa é bastante conservador. Por exemplo, ao assumir que o coeficiente de caminho mínimo esperado para ser significativo está entre 0,11 e 0,20, seriam necessárias aproximadamente 155 observações para tornar o efeito correspondente significativo a 5%. Da mesma forma, se o coeficiente de caminho mínimo esperado para ser significativo estiver entre 0,31 e 0,40, o tamanho de amostra recomendado seria 39.

1.4.2.2 Tratamento de Valor Ausente

Assim como em outras análises estatísticas, valores ausentes devem ser tratados ao usar PLS-SEM. Para limites razoáveis (ou seja, menos de 5% de valores ausentes por indicador), opções de **tratamento de valores ausentes**, como substituição de média, o EM (expectativa–algoritmo de maximização) e vizinho mais próximo (por exemplo, Hair, Black, et al., 2019), geralmente resultam em estimativas PLS-SEM apenas ligeiramente diferentes (Grimm & Wagner, 2020). Alternativamente, os pesquisadores podem optar por excluir todas as observações com valores ausentes, o que diminui a variação nos dados e pode introduzir vieses quando certos grupos de observações foram excluídos sistematicamente.

1.4.2.3 Dados não normais

O uso do PLS-SEM tem duas outras vantagens principais associadas às características dos dados (ou seja, distribuição e escalas). Em situações em que é difícil ou impossível atender aos requisitos mais rigorosos de técnicas multivariadas mais tradicionais (por exemplo, distribuição normal de dados), o PLS-SEM é sempre o método preferido. A maior flexibilidade do PLS-SEM é descrita pelo rótulo “modelagem suave”, cunhado por Wold (1982), que desenvolveu o método. Deve-se notar, no entanto, que “suave” é atribuído

1.4 • Considerações ao aplicar PLS-SEM

apenas às suposições distribucionais e não aos conceitos, modelos ou técnicas de estimativa (Lohmöller, 1989). As propriedades estatísticas do PLS-SEM fornecem estimativas de modelo muito robustas com dados que têm propriedades distribucionais normais e extremamente não normais (ou seja, assimetria e/ou curtose) (Hair, Hollingsworth et al., 2017; Hair, Matthews et al., 2017; Reinartz et al., 2009). Deve-se lembrar, no entanto, que observações influentes, outliers e colinearidade influenciam as regressões de mínimos quadrados ordinários no PLS-SEM e os pesquisadores devem avaliar os dados e resultados para essas questões (Hair, Black et al., 2019).

1.4.2.4 Escalas de Medidas

O algoritmo PLS-SEM geralmente requer que as variáveis sejam medidas em uma **escala métrica (escala de razão ou escala de intervalo)** para os indicadores do modelo de medição. Mas o método também funciona bem com escalas ordinais com pontos de dados equidistantes (ou seja, escalas quase métricas; Sarstedt & Mooi, 2019; Cap. 3.6) e com dados codificados em binário. O uso de dados codificados em binário é frequentemente um meio de incluir variáveis de controle categóricas (Hair et al., 2022) ou moderadores em modelos PLS-SEM. Em suma, indicadores binários podem ser incluídos em modelos PLS-SEM, mas requerem atenção especial. Por exemplo, usar PLS-SEM em experimentos de escolha discreta, onde o objetivo é explicar ou prever uma variável dependente binária, requer projetos específicos e rotinas de estimativa (Hair, Ringle, Gudergan, Fischer, Nitzl, & Menictas, 2019).

1.4.2.5 Dados secundários

Dados secundários são dados que já foram coletados, geralmente para um propósito de pesquisa diferente há algum tempo (Sarstedt & Mooi, 2019; Cap. 3.2.1). Dados secundários estão cada vez mais disponíveis para explorar fenômenos do mundo real. Pesquisas baseadas em dados secundários geralmente focam em um objetivo diferente do que em uma análise CB-SEM padrão, que é estritamente confirmatória por natureza. Mais precisamente, dados secundários são usados principalmente em pesquisas exploratórias para propor relações causais-preditivas em situações que têm pouca teoria claramente definida (Hair, Matthews, et al., 2017; Hair, Hollingsworth, et al., 2017). Tais configurações exigem que os pesquisadores coloquem maior ênfase em examinar todas as relações possíveis em vez de atingir o modelo fit (Nitzl, 2016). Por sua natureza, esse processo cria modelos grandes e complexos que dificilmente podem ser analisados com o método CB-SEM. Em contraste, devido aos seus requisitos de dados menos rigorosos, o PLS-SEM oferece a flexibilidade necessária para a interação entre teoria e dados (Nitzl, 2016). Ou, como Wold (1982, p. 29) observa, "a modelagem suave é projetada principalmente para contextos de pesquisa que são simultaneamente ricos em dados e teóricos". Além disso, a crescente popularidade da análise de dados secundários (por exemplo, usando dados que derivam de bancos de dados de empresas, mídias sociais, rastreamento de clientes, agências estatísticas nacionais ou dados de pesquisas disponíveis publicamente) muda o foco da pesquisa de modelagem estritamente confirmatória para preditiva e causal-preditiva. Tais configurações de pesquisa são um ajuste perfeito para a abordagem PLS-SEM orientada para previsão e ainda mais ao avaliar a previsão fora da amostra (Shmueli, et al., 2019).

O PLS-SEM também se mostra valioso para analisar dados secundários de uma perspectiva de teoria de medição. Primeiro, diferentemente das medidas de pesquisa, que geralmente são elaboradas para confirmar uma teoria bem desenvolvida, as medidas usadas em fontes de dados secundários são tipicamente

.. **Tabela 1.4** Considerações sobre dados ao aplicar PLS-SEM

- A regra de 10 vezes não é uma indicação confiável dos requisitos de tamanho de amostra no PLS-SEM. Embora as análises de poder estatístico forneçam uma estimativa de tamanho de amostra mínima mais confiável, os pesquisadores devem recorrer principalmente ao método da raiz quadrada inversa, que é superior em termos de precisão e facilidade de uso
- Quando as medidas de construção atendem às diretrizes recomendadas em termos de confiabilidade e validade, os resultados do CB-SEM e do PLS-SEM são geralmente semelhantes
- O PLS-SEM pode manipular dados extremamente anormais (por exemplo, dados com altos níveis de assimetria)
- A maioria dos procedimentos de tratamento de valores ausentes (por exemplo, substituição de média, exclusão em pares, EM e vizinho mais próximo) podem ser usados para níveis razoáveis de dados ausentes (menos de 5% ausentes por indicador) com efeito limitado nos resultados da análise
- O PLS-SEM trabalha com dados escalonados métricos, quase-métricos e categóricos (ou seja, codificados por dummy), embora haja certas limitações. O processamento de dados de experimentos de escolha discreta requer projetos e rotinas de estimativa específicos
- Devido à sua flexibilidade no tratamento de diferentes tipos de dados e medições, o PLS-SEM é o método de escolha ao analisar dados secundários

Fonte: Hair et al. (2022), Cap. 1; usado com permissão de Sage

geralmente não criado e refinado ao longo do tempo para análises confirmatórias. Assim, é muito improvável atingir o ft do modelo com medidas de dados secundários na maioria das situações de pesquisa ao usar CB-SEM. Segundo, os pesquisadores que usam dados secundários não têm a oportunidade de revisar ou refinar o modelo de medição para atingir o ft. Terceiro, uma grande vantagem do PLS-SEM ao usar dados secundários é que ele permite o uso irrestrito de medidas formativas e de item único. Isso é extremamente valioso para pesquisas envolvendo dados secundários, porque muitas medidas incluídas em bancos de dados corporativos são artefatos, como índices financeiros e outros fatores fixos (Henseler, 2017). Esses artefatos normalmente são relatados na forma de índices formativos cuja estimativa determina o uso do PLS-SEM.

. A Tabela 1.4 resume as principais considerações relacionadas às características dos dados.

1.4.3 Características do modelo

O PLS-SEM é muito flexível em suas propriedades de modelagem. Em sua forma básica, o algoritmo PLS-SEM requer que todos os modelos não incluam relacionamentos circulares ou loops de relacionamentos entre as variáveis latentes no modelo estrutural. Embora loops causais sejam às vezes especificados em pesquisas de negócios, essa característica não limita a aplicabilidade do PLS-SEM, se tais modelos forem necessários, pois as extensões de Lohmöller (1989) do algoritmo básico PLS-SEM permitem lidar com tais tipos de modelo. Outros requisitos de especificação de modelo que restringem o uso do CB-SEM, como suposições de distribuição e identificação, geralmente não são relevantes com o PLS-SEM.

As dificuldades do modelo de medição são um dos maiores obstáculos para obter uma solução com CB-SEM. Por exemplo, a estimativa de modelos complexos com muitas variáveis latentes e/ou indicadores é frequentemente impossível com CB-SEM. Em contraste,

O PLS-SEM pode ser facilmente aplicado em tais situações, uma vez que este método não é limitado por identificação e outras questões técnicas. A consideração de modelos de medição reflexivos e formativos é uma questão fundamental na aplicação do SEM (Bollen & Diamantopoulos, 2017). O PLS-SEM pode facilmente lidar com modelos de medição reflexivos e formativos e é (portanto) considerado a abordagem primária quando o modelo hipotético incorpora medidas formativas. O CB-SEM pode acomodar indicadores formativos, mas para garantir a identificação do modelo, eles devem seguir regras de especificação distintas (Diamantopoulos & Riefer, 2011). Na verdade, os requisitos muitas vezes impedem a execução da análise conforme planejado originalmente. Em contraste, o PLS-SEM não tem tais requisitos e lida com modelos de medição formativos sem nenhuma limitação. Isso também se aplica a configurações de modelo nas quais construções endógenas são medidas formativamente. A aplicabilidade do CB-SEM a tais configurações de modelo tem sido objeto de considerável debate (Cadogan & Lee, 2013; Rigdon, 2014), mas devido ao processo de estimativa multiestágio do PLS-SEM (Tenenhaus et al., 2005), que separa a medição da estimativa do modelo estrutural, a inclusão de construtos endógenos medidos formativamente não é um problema no PLS-SEM (Rigdon et al., 2014). O único problema é quando existem altos níveis de colinearidade entre as variáveis indicadoras de um modelo de medição formativo.

Diferente do CB-SEM, o PLS-SEM facilita a especificação fácil de termos de interação para mapear efeitos de moderação em um modelo de caminho. Isso torna o PLS-SEM o método de escolha em modelos de moderação simples e modelos de processo condicional mais complexos, que combinam efeitos de moderação e mediação (Sarstedt, Hair, et al., 2020). Da mesma forma, construções de ordem superior, que permitem especificar uma construção simultaneamente em diferentes níveis de abstração (Sarstedt et al., 2019), podem ser prontamente implementadas no PLS-SEM.

Finalmente, o PLS-SEM é capaz de estimar modelos muito complexos. Por exemplo, se suposições teóricas ou conceituais dão suporte a modelos grandes e dados suficientes estão disponíveis (ou seja, atendendo aos requisitos mínimos de tamanho de amostra), o PLS-SEM pode lidar com modelos de quase qualquer tamanho, incluindo aqueles com dezenas de construções e centenas de variáveis indicadoras. Conforme observado por Wold (1985), o PLS-SEM é virtualmente sem competição quando modelos de caminho com variáveis latentes são complexos em seus relacionamentos estruturais. . A Tabela 1.5 resume as regras práticas para considerações do modelo PLS-SEM.

.. Tabela 1.5 Considerações do modelo ao escolher PLS-SEM	
<ul style="list-style-type: none">• O PLS-SEM oferece muita flexibilidade no manuseio de diferentes configurações de modelos de medição. Por exemplo, o PLS-SEM pode manipular modelos de medição reflexivos e formativos, bem como medidas de itens únicos, sem requisitos ou restrições adicionais• O método permite a especificação de elementos avançados do modelo, como interação termos e construções de ordem superior• A complexidade do modelo geralmente não é um problema para PLS-SEM. Desde que os dados apropriados atendam aos requisitos mínimos de tamanho de amostra, a complexidade do modelo estrutural é virtualmente irrestrita	
Fonte: Hair et al. (2022), Cap. 1; usado com permissão de Sage)	

1.5 Diretrizes para escolher entre PLS-SEM e CB-SEM

Resumindo as discussões anteriores e com base em Hair, Risher, et al. (2019), . A Tabela 1.6 exhibe as regras práticas aplicadas ao decidir se deve usar CB-SEM ou PLS-SEM. Como pode ser visto, o PLS-SEM não é recomendado como uma alternativa universal ao CB-SEM. Ambos os métodos diferem do ponto de vista estatístico, são projetados para atingir objetivos diferentes e dependem de diferentes filosofias de medição. Nenhuma das técnicas é geralmente superior à outra, e nenhuma delas é apropriada para todas as situações (Petter, 2018). Portanto, para responder à questão de quando usar PLS-SEM versus CB-SEM, os pesquisadores devem se concentrar nas características e objetivos que distinguem os dois métodos (Hair, Sarstedt, Ringle, & Mena, 2012). Em termos gerais, com seu forte foco no modelo *fit* e à luz de seus extensos requisitos de dados, o CB-SEM é particularmente adequado para testar uma teoria no confinamento de um modelo teórico conciso. No entanto, se o objetivo principal da pesquisa for a previsão e a explicação de construtos alvo (Rigdon, 2012), o PLS-SEM deve ter preferência (Hair, Sarstedt e Ringle, 2019; Hair, Hollingsworth, Randolph e Chong, 2017).

Em geral, os pontos fortes do PLS-SEM são as limitações do CB-SEM e vice-versa, embora o PLS-SEM esteja sendo cada vez mais aplicado para desenvolvimento de escala e confr-

.. **Tabela 1.6** Regras práticas para escolher entre PLS-SEM e CB-SEM

Use PLS-SEM quando

- A análise está preocupada em testar uma estrutura teórica a partir de uma perspectiva de previsão, particularmente previsão fora da amostra
- O modelo estrutural é complexo e inclui muitos constructos, indicadores e/ou relações de modelo

O objetivo da pesquisa é compreender melhor a complexidade crescente explorando extensões teóricas de teorias estabelecidas (pesquisa exploratória para desenvolvimento de teorias)

O modelo de caminho inclui um ou mais construtos medidos formativamente

A pesquisa consiste em índices financeiros ou tipos semelhantes de artefatos

A pesquisa é baseada em dados secundários, que podem carecer de uma fundamentação abrangente com base na teoria da medição

Uma população pequena restringe o tamanho da amostra (por exemplo, pesquisa business-to-business), mas observe que o PLS-SEM também funciona muito bem com grandes tamanhos de amostra

Problemas de distribuição são uma preocupação, como a falta de normalidade

A pesquisa requer pontuações de variáveis latentes para análises de acompanhamento

Use CB-SEM quando

O objetivo é testar e confirmar a teoria

Os termos de erro requerem especificações adicionais, como a covariação

O modelo estrutural tem relações circulares

A pesquisa requer um critério global de qualidade de pés

Fonte: Adaptado de Hair, Risher, et al. (2019). Copyright © 2019 por Emerald Publishing.

Reproduzido com permissão do editor (Emerald Publishing; 7 [https://www.](https://www.emeraldgroupublishing.com)

[emeraldgroupublishing.com](https://www.emeraldgroupublishing.com))

1.5 • Diretrizes para escolher entre PLS-SEM e CB-SEM

informações (Hair, Howard e Nitzl, 2020). É importante que os pesquisadores entendam as diferentes aplicações para as quais cada abordagem foi desenvolvida e as utilizem de acordo. Os pesquisadores precisam aplicar a técnica SEM que melhor se adapta ao seu objetivo de pesquisa, características dos dados e configuração do modelo (Roldán e Sánchez-Franco, 2012).

Resumo

SEM é um método de análise de dados multivariados de segunda geração, que facilita a análise dos relacionamentos entre construtos, cada um medido por uma ou mais variáveis indicadoras. A principal vantagem do SEM é sua capacidade de medir relacionamentos de modelos complexos enquanto considera o erro de medição inerente aos indicadores.

Existem dois tipos de métodos SEM – CB-SEM e PLS-SEM. Os dois tipos de métodos diferem na maneira como estimam os parâmetros do modelo e suas suposições sobre a natureza da medição. Comparado ao CB-SEM, o PLS-SEM enfatiza a previsão, ao mesmo tempo em que relaxa as demandas sobre os dados e a especificação de relacionamentos. O PLS-SEM visa maximizar a variância explicada das variáveis latentes endógenas estimando relacionamentos parciais do modelo em uma sequência iterativa de regressões de mínimos quadrados ordinários. Em contraste, o CB-SEM estima os parâmetros do modelo, de modo que a discrepância entre as matrizes de covariância estimadas e amostrais seja minimizada. Em vez de seguir uma lógica de modelo de fator comum na estimativa de proxies de conceito como o CB-SEM faz, o PLS-SEM calcula compostos de indicadores que servem como proxies para os conceitos em pesquisa. O método não é limitado por questões de identificação, mesmo se o modelo se tornar complexo — uma situação que normalmente restringe o uso do CB-SEM — e não depende de suposições distribucionais. Além disso, o PLS-SEM pode lidar melhor com modelos de medição formativos e tem vantagens quando os tamanhos de amostra são relativamente pequenos, bem como ao analisar dados secundários. Os pesquisadores devem considerar as duas abordagens SEM como complementares e aplicar a técnica SEM que melhor se adapte ao seu objetivo de pesquisa, características de dados e configuração do modelo.

Exercício

Por favor, responda as seguintes perguntas:

1. Quando os métodos SEM seriam mais vantajosos do que as tecnologias de primeira geração? técnicas para entender relacionamentos entre variáveis?
2. Por que os pesquisadores de ciências sociais devem considerar o uso de SEM em vez de múltiplos regressão?
3. Quais são as considerações mais importantes na decisão de usar o CB-SEM ou PLS-SEM?
4. Em que circunstâncias o PLS-SEM é o método preferido em relação ao CB-SEM?
5. Por que é importante compreender a teoria ao decidir se deve usar PLS-SEM ou CB-SEM?
6. Por que o foco de previsão do PLS-SEM é uma grande vantagem do método?

1

Referências

- Abdi, H. (2010). Regressão de mínimos quadrados parciais e projeção em regressão de estrutura latente (PLS-Regression). *WIREs Computational Statistics*, 2(1), 97–106.
- Ali, F., Rasoolimanesh, S. M., Sarstedt, M., Ringle, C. M., & Ryu, K. (2018). Uma avaliação do uso da modelagem de equações estruturais de mínimos quadrados parciais (PLS-SEM) na pesquisa de hospitalidade. *The International Journal of Contemporary Hospitality Management*, 30(1), 514–538.
- Bagozzi, R. P., & Philipps, L. W. (1982). Representando e testando teorias organizacionais: Uma construção holística. *Administrative Science Quarterly*, 27(3), 459–489.
- Barclay, D. W., Higgins, C. A., & Thompson, R. (1995). A abordagem dos mínimos quadrados parciais para modelagem causal: Adoção e uso de computadores pessoais como ilustração. *Estudos de Tecnologia*, 2(2), 285–309.
- Bayonne, E., Marin-Garcia, J. A., & Alfalla-Luque, R. (2020). Mínimos quadrados parciais (PLS) em pesquisa de gestão de operações: Insights de uma revisão sistemática da literatura. *Journal of Industrial Engineering and Management*, 13(3), 565–597.
- Binz Astrachan, C. B., Patel, V. K., & Wanzenried, G. (2014). Um estudo comparativo de CB-SEM e PLS-SEM para desenvolvimento de teoria em pesquisa de empresas familiares. *Journal of Family Business Strategy*, 5(1), 116–128.
- Bollen, K. A., & Davies, W. R. (2009). Modelos de indicadores causais: identificação, estimativa e teste
Modelagem de equações estruturais, 16(3), 498–522.
- Bollen, K. A., & Diamantopoulos, A. (2017). Em defesa de indicadores formativos causais: Um relatório minoritário. *Métodos Psicológicos*, 22(3), 581–596.
- Cadogan, J. W., & Lee, N. (2013). Uso impróprio de variáveis formativas endógenas. *Journal of Pesquisa Empresarial*, 66(2), 233–241.
- Cassel, C., Hackl, P., & Westlund, A. H. (1999). Robustez do método dos mínimos quadrados parciais para estimar estruturas de qualidade de variáveis latentes. *Journal of Applied Statistics*, 26(4), 435–446.
- Cepeda Carrión, G., Cegarra-Navarro, J.-G., & Cillo, V. (2019). Dicas para usar modelagem de equações estruturais de mínimos quadrados parciais (PLS-SEM) na gestão do conhecimento. *Journal of Knowledge Management*, 23(1), 67–89.
- Chin, W. W. (1998). A abordagem dos mínimos quadrados parciais para modelagem de equações estruturais. Em G. A. Marcoulides (Ed.), *Métodos modernos para pesquisa empresarial* (pp. 295–358). Mahwah, NJ: Erlbaum.
- Chin, W. W., Cheah, J.-H., Liu, Y., Ting, H., Lim, X.-J., & Cham, T. H. (2020). Desmistificando o papel da modelagem causal-preditiva usando modelagem de equações estruturais de mínimos quadrados parciais na pesquisa de sistemas de informação. *Gestão Industrial e Sistemas de Dados*, 120(12), 2161–2209.
- Chin, W. W., Marcolin, B. L., & Newsted, P. R. (2003). Uma abordagem de modelagem de variáveis latentes de mínimos quadrados parciais para medir efeitos de interação: Resultados de um estudo de simulação de Monte Carlo e um estudo de emoção/adoção por correio eletrônico. *Information Systems Research*, 14(2), 189–217.
- Chin, W. W., & Newsted, P. R. (1999). Análise de modelagem de equações estruturais com pequenas amostras usando mínimos quadrados parciais. Em R. H. Hoyle (Ed.), *Estratégias estatísticas para pesquisa de pequenas amostras* (pp. 307–341). Thousand Oaks, CA: Sage.
- Cochran, W. G. (1977). *Técnicas de amostragem*. Nova York, NY: Wiley.
- Cohen, J. (1992). Um manual de poder. *Psychological Bulletin*, 112(1), 155–159.
- Cole, D. A., & Preacher, K. J. (2014). Análise de caminho de variável manifestada: Consequências potencialmente sérias e enganosas devido a erro de medição não corrigido. *Métodos Psicológicos*, 19(2), 300–315.
- Diamantopoulos, A. (2006). O termo de erro em modelos de medição formativa: implicações de interpretação e modelagem. *Journal of Modelling in Management*, 1(1), 7–17.
- Diamantopoulos, A., & Riefer, P. (2011). Usando medidas formativas em modelos de marketing internacional: Um conto de advertência usando a animosidade do consumidor como exemplo. Em M. Sarstedt, M. Schwaiger, & C. R. Taylor (Eds.), *Métodos de medição e pesquisa em marketing internacional (Advances in International Marketing)*, 22 (pp. 11–30). Bingley: Emerald.
- Dijkstra, T. K. (2014). A face de Janus da PLS — Resposta ao artigo do Professor Rigdon "Repensando a modelagem de mínimos quadrados parciais: Em louvor aos métodos simples". *Planejamento de longo alcance*, 47(3), 146–153.
- do Valle, P. O., & Assaker, G. (2016). Usando modelagem de equações estruturais de mínimos quadrados parciais em pesquisa de turismo: Uma revisão de pesquisas anteriores e recomendações para aplicações futuras. *Journal of Travel Research*, 55(6), 695–708.

Referências

- Faul, F., Erdfelder, E., Buchner, A., & Lang, A.-G. (2009). Análises de poder estatístico usando G*Power 3.1: Testes para análises de correlação e regressão. *Behavior Research Methods*, 41(4), 1149–1160.
- Ghasemy, M., Teeroovengadam, V., Becker, J.-M., & Ringle, C. M. (2020). Este carro rápido pode se mover mais rápido: Uma revisão da aplicação PLS-SEM na pesquisa do ensino superior. *Ensino Superior*, 80, 1121–1152.
- Goodhue, D. L., Lewis, W., & Thompson, R. (2012). O PLS tem vantagens para amostras de tamanho pequeno ou dados não normais? *MIS Quarterly*, 36(3), 981–1001.
- Grimm, MS, & Wagner, R. (2020). O impacto de valores ausentes no modelo PLS, ML e FIML ft. *Arquivos de Ciência de Dados, Série A*, 6(1), 04.
- Guttman, L. (1955). A determinação de matrizes de pontuação de fatores com implicações para cinco outros problemas básicos da teoria do fator comum. *British Journal of Statistical Psychology*, 8(2), 65–81.
- Haenlein, M., & Kaplan, A. M. (2004). Um guia para iniciantes em análise de mínimos quadrados parciais. *Compreendendo Estatística*, 3(4), 283–297.
- Hair, J. F. (2020). Métricas de previsão de próxima geração para PLS-SEM baseado em compósitos. *Gestão Industrial e Sistemas de Dados*, 121(1), 5–11.
- Hair, J. F., Binz Astrachan, C., Moisesescu, O. I., Radomir, L., Sarstedt, M., Vaithilingam, S., & Ringle, C. M. (2020). Executando e interpretando aplicações de PLS-SEM: atualizações para pesquisadores de empresas familiares. *Journal of Family Business Strategy*, 12(3), 100392.
- Hair, JF, Black, WC, Babin, BJ, & Anderson, RE (2019). *Análise de dados multivariados* (8ª ed.). Londres: Cengage Learning.
- Hair, J. F., Hollingsworth, C. L., Randolph, A. B., & Chong, A. YL (2017). Uma avaliação atualizada e expandida do PLS-SEM na pesquisa de sistemas de informação. *Industrial Management & Data Systems*, 117(3), 442–458.
- Hair, J. F., Howard, M. C., & Nitzl, C. (2020). Avaliando a qualidade do modelo de medição em PLS-SEM usando análise composta confirmatória. *Journal of Business Research*, 109, 101–110.
- Hair, JF, Hult, GTM, Ringle, CM, & Sarstedt, M. (2022). *Uma cartilha sobre modelagem de equações estruturais de mínimos quadrados parciais (PLS-SEM)* (3ª ed.). Thousand Oaks, CA: Sage.
- Hair, J. F., Matthews, L., Matthews, R., & Sarstedt, M. (2017). PLS-SEM ou CB-SEM: Diretrizes atualizadas sobre qual método usar. *International Journal of Multivariate Data Analysis*, 1(2), 107–123.
- Hair, JF, Page, MJ, & Brunsveld, N. (2020). *Fundamentos de métodos de pesquisa empresarial* (4ª ed.). Nova York, NY: Routledge.
- Hair, J. F., Ringle, C. M., Gudergan, S. P., Fischer, A., Nitzl, C., & Menictas, C. (2019). Modelagem de equações estruturais de mínimos quadrados parciais baseada em modelagem de escolha discreta: Uma ilustração na modelagem de escolha do varejista. *Business Research*, 12(1), 115–142.
- Hair, J. F., Ringle, C. M., & Sarstedt, M. (2011). PLS-SEM: De fato uma bala de prata. *Journal of Marketing Theory and Practice*, 19(2), 139–151.
- Hair, J. F., Risher, J. J., Sarstedt, M., & Ringle, C. M. (2019). Quando usar e como relatar os resultados do PLS-SEM. *European Business Review*, 31(1), 2–24.
- Hair, J. F., & Sarstedt, M. (2019). Composites vs. fatores: Implicações para escolher o SEM certo método. *Project Management Journal*, 50(6), 1–6.
- Hair, J. F., & Sarstedt, M. (2021). Explicação mais previsão – O foco lógico da pesquisa em gerenciamento de projetos. *Project Management Journal*, 52(4), 319–322.
- Hair, J. F., Sarstedt, M., Pieper, T., & Ringle, C. M. (2012). O uso da modelagem de equações estruturais de mínimos quadrados parciais na pesquisa de gestão estratégica: Uma revisão de práticas passadas e recomendações para aplicações futuras. *Long Range Planning*, 45(5–6), 320–340.
- Hair, J. F., Sarstedt, M., & Ringle, C. M. (2019). Repensando algumas das revisões do mínimo parcial quadrados. *Revista Europeia de Marketing*, 53(4), 566–584.
- Hair, J. F., Sarstedt, M., Ringle, C. M., & Gudergan, S. P. (2018). *Questões avançadas em pelo menos parcial modelagem de equações estruturais de quadrados (PLS-SEM)*. Thousand Oaks, CA: Sage.
- Hair, J. F., Sarstedt, M., Ringle, C. M., & Mena, J. A. (2012). Uma avaliação do uso de modelagem de equações estruturais de mínimos quadrados parciais em pesquisa de marketing. *Journal of the Academy of Marketing Science*, 40(3), 414–433.
- Henseler, J. (2017). Fazendo a ponte entre design e pesquisa comportamental com equação estrutural baseada em variância modelagem. *Revista de Publicidade*, 46(1), 178–192.

- Henseler, J., Dijkstra, T. K., Sarstedt, M., Ringle, C. M., Diamantopoulos, A., Straub, D. W., Ketchen, DJ, Hair, JF, Hult, GTM, & Calantone, R. J. (2014). Crenças comuns e realidade sobre mínimos quadrados parciais: Comentários sobre Rönkkö & Evermann (2013). *Métodos de Pesquisa Organizacional*, 17(1), 182–209.
- Hui, BS, & Wold, H. (1982). Consistência e consistência em geral de estimativas de mínimos quadrados parciais. Em KG Jöreskog & H. Wold (Eds.), *Sistemas sob observação indireta, parte II* (pp. 119–130). Amsterdã: Holanda do Norte.
- Hwang, H., Sarstedt, M., Cheah, J.-H., & Ringle, C. M. (2020). Uma análise conceitual de pesquisa metodológica sobre modelagem de equações estruturais baseada em compósitos: Bridging PLSPM e GSCA. *Comportamentometria*, 47(1), 219–241.
- JCGM/WG1 (2008). Comitê conjunto para guias em metrologia/grupo de trabalho sobre a expressão de incerteza em medição (JCGM/WG1): Avaliação de dados de medição - guia para a expressão de incerteza em medição. Recuperado de https://www.bipm.org/utls/common/documentos/jcgm/JCGM_100_2008_E.pdf. Data de acesso: 26 fev 2021
- Jöreskog, K. G. (1973). Um método geral para estimar um sistema de equações estruturais lineares. Em A. S. Goldberger & O. D. Duncan (Eds.), *Modelos de equações estruturais nas ciências sociais* (pp. 255–284). Nova York, NJ: Seminar Press.
- Jöreskog, KG, & Wold, H. (1982). As técnicas ML e PLS para modelagem com variáveis latentes: Aspectos históricos e comparativos. Em H. Wold & KG Jöreskog (Eds.), *Sistemas sob observação indireta, parte I* (pp. 263–270). Amsterdã: Holanda do Norte.
- Kaufmann, L., & Gaeckler, J. (2015). Uma revisão estruturada de mínimos quadrados parciais em pesquisa de gestão da cadeia de suprimentos. *Journal of Purchasing and Supply Management*, 21(4), 259–272.
- Khan, G., Sarstedt, M., Shiao, W.-L., Hair, J. F., Ringle, C. M., & Fritze, M. (2019). Pesquisa metodológica sobre modelagem de equações estruturais de mínimos quadrados parciais (PLS-SEM): Uma análise de rede social. *Pesquisa na Internet*, 29(3), 407–429.
- Kock, N., & Hadaya, P. (2018). Estimativa do tamanho mínimo da amostra em PLS-SEM: Os métodos da raiz quadrada inversa e gama-exponencial. *Information Systems Journal*, 28(1), 227–261.
- Lee, L., Petter, S., Fayard, D., & Robinson, S. (2011). Sobre o uso de modelagem de caminho de mínimos quadrados parciais em pesquisa contábil. *International Journal of Accounting Information Systems*, 12(4), 305–328.
- Lohmöller, J.-B. (1989). *Modelagem de caminho de variável latente com mínimos quadrados parciais*. Heidelberg: Physica.
- Manley, S. C., Hair, J. F., Williams, R. I., & McDowell, W. C. (2020). Novos métodos essenciais de análise PLS-SEM para sua caixa de ferramentas analíticas de empreendedorismo. *International Entrepreneurship and Management Journal*, a ser lançado.
- Marcoulides, G. A., & Chin, W. W. (2013). Você escreve, mas outros leem: Mal-entendidos metodológicos comuns em PLS e métodos relacionados. Em H. Abdi, W. W. Chin, V. Esposito Vinzi, G. Russolillo, & Trinchera (Eds.), *Novas perspectivas em mínimos quadrados parciais e métodos relacionados* (pp. 31–64). Nova Iorque, NY: Springer.
- Marcoulides, G. A., & Saunders, C. (2006). PLS: Uma bala de prata? *MIS Quarterly*, 30(2), iii–ix.
- Mateos-Aparicio, G. (2011). Métodos de mínimos quadrados parciais (PLS): origens, evolução e aplicação às ciências sociais. *Communications in Statistics—Theory and Methods*, 40(13), 2305–2317.
- McDonald, R. P. (1996). Análise de caminho com variáveis compostas. *Pesquisa comportamental multivariada*, 31(2), 239–270.
- Nitzl, C. (2016). O uso de modelagem de equações estruturais de mínimos quadrados parciais (PLS-SEM) em pesquisa de contabilidade gerencial: Direções para o desenvolvimento futuro da teoria. *Journal of Accounting Literature*, 37 (dezembro), 19–35.
- Nitzl, C., & Chin, W. W. (2017). O caso da modelagem de caminho de mínimos quadrados parciais (PLS) em gestão pesquisa contábil. *Journal of Management Control*, 28, 137–156.
- Peng, D. X., & Lai, F. (2012). Usando mínimos quadrados parciais em pesquisa de gestão de operações: Uma diretriz prática e resumo de pesquisas anteriores. *Journal of Operations Management*, 30(6), 467–480.
- Petter, S. (2018). "Haters gonna hate": PLS e pesquisa em sistemas de informação. *ACM SIGMIS Base de dados: DATABASE para avanços em sistemas de informação*, 49(2), 10–13.
- Rasoolimanesh, SM, Ringle, CM, Sarstedt, M., & Olya, H. (2021). O uso combinado de abordagens orientadas à predição: modelagem de equações estruturais de mínimos quadrados parciais e qualificação fuzzyset

- análise comparativa quantitativa. *International Journal of Contemporary Hospitality Management*, 33(5), 1571–1592.
- Reinartz, W., Haenlein, M., & Henseler, J. (2009). Uma comparação empírica da eficácia de SEM baseado em covariância e baseado em variância. *International Journal of Research in Marketing*, 26(4), 332–344.
- Rhemtulla, M., van Bork, R., & Borsboom, D. (2020). Pior que erro de medição: Consequências de modelos de medição de variáveis latentes inapropriados. *Métodos Psicológicos*, 25(1), 30–45.
- Richter, N. F., Cepeda Carrión, G., Roldán, J. L., & Ringle, C. M. (2016). Pesquisa de gestão europeia usando modelagem de equações estruturais de mínimos quadrados parciais (PLS-SEM): Editorial. *Revista Europeia de Gestão*, 34(6), 589–597.
- Richter, N. F., Schubring, S., Hauff, S., Ringle, C. M., & Sarstedt, M. (2020). Quando os preditores de resultados são necessários: Diretrizes para o uso combinado de PLS-SEM e NCA. *Gestão Industrial e Sistemas de Dados*, 120(12), 2243–2267.
- Richter, N. F., Sinkovics, R. R., Ringle, C. M., & Schlägel, C. (2016). Um olhar crítico sobre o uso de SEM em Pesquisa de Negócios Internacionais. *International Marketing Review*, 33(3), 376–404.
- Rigdon, E. E. (2012). Repensando a modelagem de caminho de mínimos quadrados parciais: Em louvor aos métodos simples. *Planejamento de longo prazo*, 45(5–6), 341–358.
- Rigdon, E. E. (2013). Modelagem de caminho de mínimos quadrados parciais. Em G. R. Hancock & R. D. Mueller (Eds.), *Modelagem de equações estruturais: Um segundo curso* (2ª ed., pp. 81–116). Charlotte, NC: Information Age.
- Rigdon, E. E. (2014). Repensando a modelagem de caminho de mínimos quadrados parciais: quebrando correntes e avançando. *Long Range Planning*, 47(3), 161–167.
- Rigdon, E. E. (2016). Escolhendo a modelagem de caminho PLS como método analítico na gestão europeia pesquisa: Uma perspectiva realista. *European Management Journal*, 34(6), 598–605.
- Rigdon, E. E., Becker, J.-M., Rai, A., Ringle, C. M., Diamantopoulos, A., Karahanna, E., Straub, D. W., & Dijkstra, T. K. (2014). Confrontando antecedentes e indicadores formativos: Um comentário sobre Aguirre-Urreta e Marakas. *Information Systems Research*, 25(4), 780–784.
- Rigdon, E. E., Becker, J.-M., & Sarstedt, M. (2019a). Indeterminação de fator como incerteza metrológica: implicações para o avanço da medição psicológica. *Pesquisa comportamental multivariada*, 54(3), 429–443.
- Rigdon, E. E., Becker, J.-M., & Sarstedt, M. (2019b). O parcelamento não pode reduzir a indeterminação dos fatores na análise fatorial: uma nota de pesquisa. *Psychometrika*, 84(3), 772–780.
- Rigdon, E. E., Sarstedt, M., & Becker, J.-M. (2020). Quantificar a incerteza na pesquisa comportamental. *Natureza Comportamento Humano*, 4(4), 329–331.
- Rigdon, E. E., & Sarstedt, M. (2021). Contabilização da incerteza na medição de fenômenos de marketing não observáveis. Em H. Baumgartner & B. Weijters (Eds.), *Review of marketing research*, a ser publicado.
- Rigdon, E. E., Sarstedt, M., & Ringle, C. M. (2017). Sobre a comparação de resultados de CB-SEM e PLS-SEM: Cinco perspectivas e cinco recomendações. *Marketing ZFP*, 39(3), 4–16.
- Ringle, C. M., Sarstedt, M., Mitchell, R., & Gudergan, S. P. (2020). Modelagem de equações estruturais de mínimos quadrados parciais em pesquisa de GARH. *International Journal of Human Resource Management*, 31(12), 1617–1643.
- Ringle, C. M., Sarstedt, M., & Straub, D. W. (2012). Um olhar crítico sobre o uso de PLS-SEM em MIS *Trimestral. MIS Trimestral*, 36(1), iii–xiv.
- Roldán, J. L., & Sánchez-Franco, M. J. (2012). Modelagem de equações estruturais baseada em variância: Diretrizes para usar mínimos quadrados parciais em pesquisa de sistemas de informação. Em M. Mora, O. Gelman, A. L. Steenkamp, & M. Raisinghani (Eds.), *Metodologias de pesquisa, inovações e filosofias em engenharia de sistemas de software e sistemas de informação* (pp. 193–221). Hershey, PA: IGI Global.
- Rönkkö, M., & Evermann, J. (2013). Um exame crítico das crenças comuns sobre o mínimo parcial modelagem de caminho de quadrados. *Métodos de Pesquisa Organizacional*, 16(3), 425–448.
- Rönkkö, M., McIntosh, C. N., & Antonakis, J. (2015). Sobre a adoção de mínimos quadrados parciais em pesquisa psicológica: Caveat emptor. *Personality and Individual Differences*, 87 (dezembro), 76–84.

1

- Rossiter, J. R. (2011). *Medição para as ciências sociais: O método C-OAR-SE e por que ele deve substituir a psicometria*. Berlim: Springer.
- Russo, D., & Stol, K.-J. (2021). PLS-SEM para pesquisa em engenharia de software: Uma introdução e pesquisa. *Pesquisas de computação da ACM*, 54(4), Artigo 78.
- Sarstedt, M., Bengart, P., Shaltoni, A. M., & Lehmann, S. (2018). O uso de métodos de amostragem em pesquisa de publicidade: Uma lacuna entre teoria e prática. *International Journal of Advertising*, 37(4), 650–663.
- Sarstedt, M., Hair, J. F., Cheah, J.-H., Becker, J.-M., & Ringle, C. M. (2019). Como especificar, estimar e validar modelos de ordem superior. *Australasian Marketing Journal*, 27(3), 197–211.
- Sarstedt, M., Hair, J. F., Nitzl, C., Ringle, C. M., & Howard, M. C. (2020). Além de uma análise em tandem de SEM e PROCESS: Use PLS-SEM para análises de mediação! *International Journal of Market Research*, 62(3), 288–299.
- Sarstedt, M., Hair, J. F., Ringle, C. M., Thiele, K. O., & Gudergan, S. P. (2016). Problemas de estimativa com PLS e CB-SEM: Onde está o viés! *Journal of Business Research*, 69(10), 3998–4010.
- Sarstedt, M., & Mooi, EA (2019). *Um guia conciso para pesquisa de mercado: O processo, dados e métodos usando estatísticas IBM SPSS* (3ª ed.). Berlim: Springer.
- Sarstedt, M., Ringle, CM, Cheah, J.-H., Ting, H., Moisescu, OI, & Radomir, L. (2020). Estrutural verificações de robustez do modelo em PLS-SEM. *Tourism Economics*, 26(4), 531–554.
- Sarstedt, M., & Danks, N. (2021). Predição na pesquisa de HRM — Uma lacuna entre retórica e realidade. *Human Resource Management Journal*, em breve.
- Sarstedt, M., Ringle, C. M., Smith, D., Reams, R., & Hair, J. F. (2014). Modelagem de equações estruturais de mínimos quadrados parciais (PLS-SEM): Uma ferramenta útil para pesquisadores de empresas familiares. *Journal of Family Business Strategy*, 5(1), 105–115.
- Schneeweiß, H. (1991). Modelos com variáveis latentes: LISREL versus PLS. *Estatística Neerlandica*, 45(2), 145–157.
- Schuberth, F., Henseler, J., & Dijkstra, T. K. (2018). Análise composta confirmatória. *Frontiers in Psychology*, 9, 2541.
- Tenenhaus, M., Esposito Vinzi, V., Chatelin, Y.-M., & Lauro, C. (2005). Modelagem de caminho PLS. *Estatística Computacional e Análise de Dados*, 48(1), 159–205.
- Usakli, A., & Kucukergin, K. G. (2018). Usando modelagem de equações estruturais de mínimos quadrados parciais em hospitalidade e turismo: Os pesquisadores seguem diretrizes práticas? *International Journal of Contemporary Hospitality Management*, 30(11), 3462–3512.
- Willaby, H., Costa, D., Burns, B., MacCann, C., & Roberts, R. (2015). Testando modelos complexos com tamanhos de amostra pequenos: Uma visão geral histórica e demonstração empírica do que os mínimos quadrados parciais (PLS) podem oferecer à psicologia diferencial. *Personality and Individual Differences*, 84, 73–78.
- Wold, H. (1982). Modelagem suave: O design básico e algumas extensões. Em KG Jöreskog & H. Wold (Eds.), *Sistemas sob observações indiretas, parte II* (pp. 1–54). Amsterdã: Holanda do Norte.
- Wold, H. (1985). Mínimos quadrados parciais. Em S. Kotz & N. L. Johnson (Eds.), *Enciclopédia de estatística ciências* (pp. 581–591). Nova York, NY: John Wiley.
- Wold, S., Sjöström, M. e Eriksson, L. (2001). Regressão PLS: Uma ferramenta básica de quimiometria. *Quimiometria e sistemas de laboratório inteligentes*, 58(2), 109–130.
- Zeng, N., Liu, Y., Gong, P., Hertogh, M., & König, M. (2021). Faça o PLS certo e faça o PLS certo: Uma revisão crítica da aplicação do PLS na pesquisa de gerenciamento de construção. *Frontiers of Engineering Management*, 8(3), 356–369.

Leituras sugeridas

- Chin, W. W. (1998). A abordagem dos mínimos quadrados parciais para modelagem de equações estruturais. Em G. A. Marcoulides (Ed.), *Métodos modernos para pesquisa empresarial* (pp. 295–358). Mahwah, NJ: Erlbaum.
- Hair, JF, Binz Astrachan, C., Moisescu, OI, Radomir, L., Sarstedt, M., Vaithilingam, S., & Ringle, CM (2020). Executando e interpretando aplicações de PLS-SEM: atualizações para pesquisadores de empresas familiares. *Journal of Family Business Strategy*, 12(3), 100392.

- Jöreskog, KG, & Wold, H. (1982). As técnicas ML e PLS para modelagem com variáveis latentes: Aspectos históricos e comparativos. Em H. Wold & KG Jöreskog (Eds.), *Sistemas sob observação indireta, parte I* (pp. 263–270). Amsterdã: Holanda do Norte.
- Lohmöller, J.-B. (1989). *Modelagem de caminho de variável latente com mínimos quadrados parciais*. Heidelberg: Physica.
- Rigdon, E. E. (2012). Repensando a modelagem de caminho de mínimos quadrados parciais: Em louvor aos métodos simples. *Planejamento de longo prazo*, 45(5–6), 341–358.
- Sarstedt, M., Hair, J. F., Ringle, C. M., Thiele, K. O., & Gudergan, S. P. (2016). Problemas de estimativa com PLS e CBSEM: Onde está o viés! *Journal of Business Research*, 69(10), 3998–4010.
- Tenenhaus, M., Esposito Vinzi, V., Chatelin, Y.-M., & Lauro, C. (2005). Modelagem de caminho PLS. *Estatística Computacional e Análise de Dados*, 48(1), 159–205.
- Wold, H. (1982). Modelagem suave: O design básico e algumas extensões. Em KG Jöreskog & H. Wold (Eds.), *Sistemas sob observações indiretas, parte II* (pp. 1–54). Amsterdã: Holanda do Norte.

Acesso aberto Este capítulo está licenciado sob os termos da Licença Internacional Creative Commons Atribuição 4.0 (<http://creativecommons.org/licenses/by/4.0/>), que permite uso, compartilhamento, adaptação, distribuição e reprodução em qualquer meio ou formato, desde que você dê os devidos créditos ao(s) autor(es) original(ais) e à fonte, forneça um link para a licença Creative Commons e indique se alterações foram feitas.

As imagens ou outros materiais de terceiros neste capítulo estão incluídos na licença Creative Commons do capítulo, a menos que indicado de outra forma em uma linha de crédito para o material. Se o material não estiver incluído na licença Creative Commons do capítulo e seu uso pretendido não for permitido por regulamentação estatutária ou exceder o uso permitido, você precisará obter permissão diretamente do detentor dos direitos autorais.

